

基于多种机器学习模型的 糖尿病风险预测研究

《机器学习》课程项目

柯文丽 10232140444 王佳妮 10232140440

秦琪 10232140402 何晨东 10230730401

华东师范大学 计算机科学与技术学院

摘要—面向结构化健康指标的糖尿病风险预测，是健康管理场景中常见的二分类任务。本文基于 Pima Indians Diabetes Database 构建糖尿病风险预测流程，将原始数据中缺乏合理医学含义的 0 值作为隐式缺失处理，并完成异常值裁剪和特征标准化，并采用分层抽样划分训练集、验证集和测试集。在固定数据划分和相同预处理流程下，本文以 Logistic Regression 为基准模型，比较多种传统机器学习与集成学习模型，再根据验证集结果选择候选模型进行网格搜索、分层交叉验证和分类阈值优化。实验结果表明，阈值优化后的 SVM 在测试集上的 Accuracy、Precision、Recall、F1-score 和 ROC AUC 分别为 0.7403、0.5972、0.7963、0.6825 和 0.8215。与 Logistic Regression 基准模型相比，最终模型的 Recall 和 F1-score 分别提升 0.0926 和 0.0384，在当前固定划分下能够识别更多高风险样本，更符合风险筛查中减少漏判的目标。本文还基于 Gradio 构建了单样本交互式演示系统，输出风险分数、风险等级、输入异常校验和简要提示。该风险分数未经概率校准，仅用于风险提示和系统演示，不能替代医学诊断。

Index Terms—糖尿病风险预测，Pima Indians Diabetes Database，机器学习，支持向量机，分类阈值优化，风险筛查

I. 引言

糖尿病是一类以慢性高血糖为主要表现的代谢性疾病。长期血糖控制不佳会增加心血管、肾脏、神经和视网膜等并发症风险。世界卫生组织指出，糖尿病仍是重要公共卫生问题；Reza 等的研究也强调，早期诊断和管理有助于预防或延缓并发症发生 [1], [2]。在常规筛查场景中，结构化体检指标比复杂医学检查更容易获取，因此利用机器学习模型进行糖尿病风险预测具有实际意义。

本文使用 Pima Indians Diabetes Database 开展二分类实验。该数据集包含 768 名样本、8 个数值型输入特征和 1 个二分类标签，样本均为至少 21 岁的 Pima Indian 女性 [3]。该数据集规模较小但变量清晰，适合在统一预处理流程下比较不同分类算法的性能和误判特征。

本文围绕糖尿病风险预测流程展开：数据层面完成缺失值、异常值、标准化和分层划分处理；模型层面以 Logistic Regression 作为可解释基准，并在相同实验设置下比较 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM 等多种模型；结果分析部分结合分类指标、ROC AUC、混淆矩阵和特征解释评估模型表现，并将最终模型接入交互式演示系统。

II. 相关工作

Smith 等较早使用 ADAP 学习算法研究 Pima 数据集上的糖尿病发病预测，并采用敏感性、特异性和 ROC 曲线等临床测试指标进行分析 [4]。Sisodia 等比较了 Decision Tree、SVM 和 Naive Bayes，Zou 等则结合特征降维比较了 Decision Tree、Random Forest 和神经网络；这些工作表明，Pima 数据集常被用于传统分类器和树模型比较 [5], [6]。

Khanam 和 Foo 系统比较了多种机器学习和神经网络模型，并强调缺失值填补、异常值处理、特征选择和归一化会影响最终结果 [7]。Reza 等进一步使用 stacking 方法融合传统机器学习模型和神经网络模型，并比较训练/测试划分与交叉验证协议 [2]。这些研究为本文采用多模型比较、统一预处理和多指标评估提供了依据。

在可解释性方面，Lundberg 和 Lee 提出的 SHAP 方法可通过特征边际贡献解释模型输出 [8]。李佳思和成路平等的研究均指出 Glucose、BMI 和 Age 等变量在糖尿病预测中较为重要 [9], [10]。

III. 数据集与预处理

A. 数据集来源与变量定义

本文实验使用 Pima Indians Diabetes Database。该数据集包含 768 条样本、8 个输入特征和 1 个二分类标签，所有输入特征均为数值型 [3]。标签 Outcome 中，0 表示未检测为糖尿病阳性，1 表示检测为糖尿病阳性。原始数据包含 500 个阴性样本和 268 个阳性样本，阳性样本占比约为 34.9%。图 1 展示了该类别分布。




图 1. 原始数据集中 Outcome 的类别分布

8 个输入变量的含义见表 I。

表 I
PIMA 数据集输入特征及 0 值处理

特征	含义	单位/说明	0 值处理
Pregnancies	怀孕次数	次	保留
Glucose	口服葡萄糖耐量测试 2 小时血糖浓度	-	缺失
BloodPressure	舒张压	mmHg	缺失
SkinThickness	三头肌皮褶厚度	mm	缺失
Insulin	2 小时血清胰岛素	$\mu\text{U/ml}$	缺失
BMI	身体质量指数	kg/m^2	缺失
DPF	糖尿病家族遗传指数	指数	保留
Age	年龄	岁	保留

Pregnancies 的 0 值表示没有怀孕经历，属于合理取值。Glucose、BloodPressure、SkinThickness、Insulin 和 BMI 的 0 值缺乏合理医学含义，因此本文将这些 0 值视作缺失或未测量记录 [2], [7]。

B. 缺失值与异常值处理

原始数据没有显式空值，但存在由不合理 0 值体现的隐式缺失。其中，Glucose 有 5 个 0，BloodPressure 有 35 个 0，SkinThickness 有 227 个 0，Insulin 有 374 个 0，BMI 有 11 个 0，若直接删除这些样本，会显著减少可用数据。由于中位数比均值更不易受偏态分布和极端值影响，因此本文先将上述 5 个变量中的不合理 0 值标记为缺失，再使用训练集拟合得到的中位数填充。训练集填充值为 Glucose 117.0、BloodPressure 72.0、SkinThickness 29.0、Insulin 125.0 和 BMI 32.4。

在完成中位数填充后，本文采用 IQR 规则处理异常值。IQR 方法对特征分布形状没有正态性假设，适合 Pima 数据集中偏态较明显的生理指标。对每个特征，仅使用训练集计算第一四分位数 Q_1 、第三四分位数 Q_3 和四分位距

$$IQR = Q_3 - Q_1.$$

下界定义为 $\max(Q_1 - 1.5IQR, 0)$ ，上界定义为 $Q_3 + 1.5IQR$ 。随后使用训练集得到的边界对训练集、验证集和测试集进行一致裁剪，以避免验证集和测试集信息参与参数估计。表 II 给出了最终使用的裁剪边界。

表 II
训练集拟合得到的 IQR 裁剪边界

特征	下界	上界
Pregnancies	0.00	13.50
Glucose	38.75	200.75
BloodPressure	40.00	104.00
SkinThickness	1.00	57.00
Insulin	0.00	355.50
BMI	13.80	50.60
Diabetes Pedigree	0.00	1.2325
Age	0.00	65.25

C. 数据划分与标准化

数据划分采用分层抽样，随机种子为 42。首先划分 20% 样本作为测试集，再从剩余样本中划分 20% 作为验证集。最终训练集、验证集和测试集比例约为 64%、16% 和 20%，样本量和类别分布如表 III 所示。

表 III
分层划分后的样本量与类别分布

数据集	总样本数	0 类	1 类
训练集	491	320	171
验证集	123	80	43
测试集	154	100	54

由于阳性样本约占 35%，分层抽样可以保持各子集的阳性/阴性比例接近原始数据。验证集用于模型选择和调参，测试集留到方案确定后进行独立评估，以减少调参过程对测试集的过拟合。

该划分比例兼顾了训练样本数量和评估结果的独立性。训练集用于估计缺失填补、异常值裁剪和标准化参数，并承担所有模型的拟合过程。固定随机种子使后续实验能够在相同数据划分上复现，也便于比较不同模型或不同阈值设置带来的性能变化。

标准化采用训练集拟合的均值和标准差。Logistic Regression、SVM、KNN 和神经网络等模型对特征尺度敏感，因此统一尺度有助于减少量纲差异对训练的影响。其余数据沿用这组参数进行变换，避免把评估数据的信息带入训练过程。

D. 探索性分析

图 2 展示了各特征在不同标签下的分布，并在存在不合理 0 值的变量上标注 0 值数量。




图 2. 按 Outcome 分组的原始特征分布

从图中可以看到，阳性样本在 Glucose 和 BMI 上整体更偏向较高取值，Age 和 Pregnancies 也呈现一定右移趋势；同时，SkinThickness 和 Insulin 的 0 值数量明显较多，这与前文将其作为隐式缺失处理的决定一致。

图 3 由原始数据中的全部数值列计算 Pearson 相关系数得到，并用热力图展示特征之间以及特征与标签之间的线性相关程度。

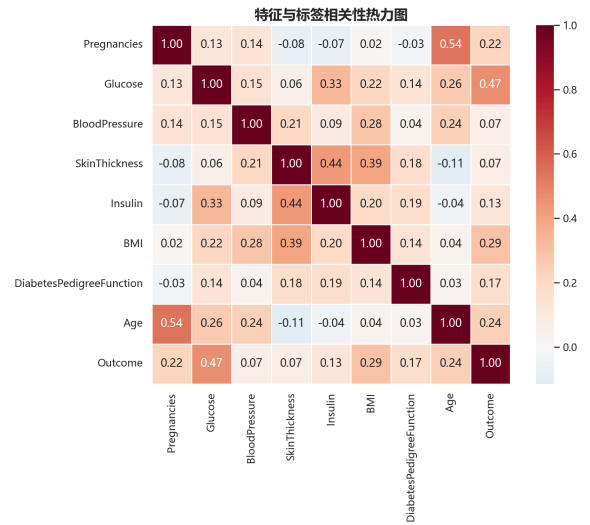


图 3. 原始特征与 Outcome 的 Pearson 相关性热力图

从标签 Outcome 对应的相关系数看，Glucose 与标签的相关性最高，约为 0.47；BMI、Age、Pregnancies 和 DiabetesPedigreeFunction 也与标签呈正相关，但强度弱于 Glucose。特征之间的相关性总体不算很高，其中 Pregnancies 与 Age、SkinThickness 与 Insulin、SkinThickness 与 BMI 的相关性相对更明显。这些结果说明血糖、体重相关指标和年龄信息可能对模型预测较有帮助，但相关性只反映线性统计关联，不能直接解释为医学因果关系。

IV. 方法与实验设置

A. 整体流程

为保证不同模型可比，本文将数据划分、预处理参数估计、模型训练和测试评估分开处理。原始数据先标记缺乏合理医学含义的 0 值，再通过分层抽样划分为训练集、验证集和测试集。中位数填充器、IQR 裁剪边界和标准化器均由训练集确定；验证集负责模型筛选、超参数调优和分类阈值选择；方案确定后，再用测试集进行一次独立评估。图 4 概括了从原始数据到模型评估及系统推理的完整流程。

该流程先完成隐式缺失标记和分层划分，再将训练阶段得到的填充器、裁剪边界、标准化器与模型一起保存。系统端输入沿用相同的特征顺序和变换规则，因此交互界面的风险输出与离线评估处在同一处理流程中。




图 4. 糖尿病风险预测系统总体技术路线

B. 模型选择

本文首先使用 Logistic Regression 作为可解释基准模型：设置 `class_weight="balanced"`、最大迭代次数 1000、随机种子 42，并将其作为后续模型比较的参照。在此基础上，多模型比较阶段沿用上一节的数据划分和预处理结果。所有候选模型均只在训练集上拟合，再分别在验证集和测试集上按同一指标评估，从而保证不同模型之间以及与 Logistic Regression 基准模型之间的可比性。

除 Logistic Regression 基准模型外，实验纳入 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM。这些模型覆盖距离方法、线性模型、最大间隔分类器、单树模型和集成学习，便于在相同预处理流程下比较不同建模假设。

评价时，本文对每个模型都计算 Accuracy、Precision、Recall、F1-score 和 ROC AUC，并保持验证集与测试集的计算口径一致。由于糖尿病风险预测属于筛查任务，漏判高风险样本可能使潜在阳性个体错过进一步检查，因此模型比较不能只关注 Accuracy，还应重点观察 Recall 和 F1-score，并结合 ROC AUC 衡量模型对正负样本的整体排序能力。

C. 超参数调优协议

多模型比较完成后，本文仅依据验证集结果确定调参对象，避免测试集信息参与模型选择。SVM 在验证集 Recall 和 F1-score 上表现最好，Logistic Regression 作为可解释线性基准保留作对照，因此调参阶段聚焦于这两个模型。

调参采用 GridSearchCV，交叉验证方式为 5 折 StratifiedKFold，划分时设置 `shuffle=True` 和随机种子 42，搜索评分指标为 ROC AUC。Logistic Regression 的搜索空间包括 $C \in \{0.01, 0.1, 1, 10, 100\}$ 、`solver` $\in \{\text{liblinear}, \text{lbfgs}\}$ 、`penalty=l2` 以及 `class_weight`

$\in \{\text{None}, \text{balanced}\}$ 。SVM 采用 RBF 核，搜索空间包括 $C \in \{0.1, 1, 10, 100\}$ 、 $\text{gamma} \in \{\text{scale}, 0.01, 0.1, 1\}$ 以及 `class_weight` $\in \{\text{None}, \text{balanced}\}$ 。

得到最优超参数后，本文在验证集上以 0.01 为步长搜索 0.25–0.75 范围内的分类阈值，并以 F1-score、Recall 和 ROC AUC 综合排序。由于筛查场景更关注减少假阴性，阈值选择优先保证较高 Recall。

最终模型选择 SVM，最优参数为 $C = 10.0$ 、 $\text{gamma}=0.01$ 、`class_weight=None`，验证集上选择的分类阈值为 0.30。实验过程保留调参记录、最优参数配置和最终模型对象，以支持模型选择过程的复现。

D. 评价指标

糖尿病预测是类别不平衡二分类问题，单一 Accuracy 可能掩盖阳性样本漏判。因此本文纳入 Accuracy、Precision、Recall、F1-score 和 ROC AUC 作为评价指标。其中 Recall 衡量真实阳性样本被正确识别的比例；在筛查场景中，假阴性意味着潜在高风险个体被漏掉，因此 Recall 和 F1-score 比单纯 Accuracy 更需要关注。ROC AUC 不依赖单一分类阈值，用于衡量模型对阳性样本和阴性样本的整体区分能力。

V. 结果与分析

A. 模型性能比较

表 IV 汇总了 Logistic Regression 基准模型以及 7 个候选模型在验证集和测试集上的性能。所有模型使用相同的预处理结果和固定数据划分，并仅使用训练集进行拟合，验证集结果用于候选模型筛选，测试集结果用于观察基础参数设置下的独立表现。

图 5 展示了各模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC。糖尿病风险预测不能只看总体预测正确率，本文在比较候选模型时重点考察 Recall 和

表 IV
不同模型在验证集与测试集上的性能比较

模型	Val Acc.	Val Prec.	Val Recall	Val F1	Val AUC	Test Acc.	Test Prec.	Test Recall	Test F1	Test AUC
Logistic Regression	0.7642	0.6346	0.7674	0.6947	0.8709	0.7273	0.5938	0.7037	0.6441	0.8154
KNN	0.7805	0.7105	0.6279	0.6667	0.8581	0.7273	0.6154	0.5926	0.6038	0.7675
Decision Tree	0.7886	0.7429	0.6047	0.6667	0.7461	0.6948	0.5714	0.5185	0.5437	0.6543
Random Forest	0.7967	0.7368	0.6512	0.6914	0.8365	0.7338	0.6444	0.5370	0.5859	0.8275
SVM	0.7967	0.6667	0.8372	0.7423	0.8759	0.7468	0.6087	0.7778	0.6829	0.8157
Gradient Boosting	0.7236	0.6098	0.5814	0.5952	0.8311	0.7013	0.5952	0.4630	0.5208	0.7959
XGBoost	0.7561	0.6857	0.5581	0.6154	0.7985	0.7468	0.6596	0.5741	0.6139	0.7967
LightGBM	0.7724	0.6923	0.6279	0.6585	0.8308	0.7273	0.6304	0.5370	0.5800	0.8002




图 5. 不同模型在测试集上的性能指标比较

F1-score，并使用 ROC AUC 衡量模型对正负样本的整体排序能力。

表 IV 和图 5 显示，在基础参数设置下，SVM 与 XGBoost 的测试集 Accuracy 均为 0.7468，并列所有模型中的最高值。其中 SVM 的 Recall 和 F1-score 分别为 0.7778 和 0.6829，均为候选模型最高，较 Logistic Regression 基准有明显提升。Random Forest 的 ROC AUC 最高，为 0.8275，但 Recall 仅为 0.5370，说明其排序能力较好而默认阈值下漏判较多。XGBoost 的 Precision 较高但 Recall 偏低，LightGBM 表现较均衡，Decision Tree 和 Gradient Boosting 相对较弱。后续调参只依据验证集结果筛选候选模型：SVM 在验证集 Recall 和 F1-score 上表现最好，因此作为主要调参对象；Logistic Regression 则作为可解释线性基准保留作对照。本节展示的测试集结果不参与模型选择，仅作为固定划分下的独立对照结果。

验证集与测试集的差异也说明，小样本条件下单次划分会带来一定波动。例如，SVM 的验证集 Recall 为 0.8372，测试集 Recall 为 0.7778；Random Forest 则在测试集上取得较高 AUC，但默认阈值下的 Recall 较低。

因此，模型选择不能仅依据某一个指标，而应同时考察验证集上的筛查目标、漏判代价以及后续阈值调整空间。ROC AUC 描述模型在全部可能阈值下区分正负样本的总体能力，但不直接代表某个部署阈值下的分类效果 [11]；这也是本文同时报告 AUC、Recall、Precision 和 F1-score 的原因。

不同模型之间的性能差异还反映了数据规模与模型复杂度之间的关系。Pima 数据集仅包含 768 条记录和 8 个结构化特征，复杂集成模型虽然能够刻画更高阶的非线性关系，但在样本有限、部分变量缺失比例较高的条件下，其优势可能被估计方差和过拟合风险抵消。例如，XGBoost 与 SVM 的测试集 Accuracy 相同，但前者 Recall 明显较低；Decision Tree 的验证集与测试集 AUC 均低于多数候选模型，也说明单棵树对当前数据划分较为敏感。相较之下，Logistic Regression 和 SVM 的决策边界受到更强约束，在当前固定划分下取得了相对更均衡的测试集表现。

上述现象与既有糖尿病预测研究中的观察基本一致：模型性能受数据来源、预处理方式、评价指标及划分策略共同影响，单一算法通常难以在所有实验设置下

保持最优 [5]–[7]。因此，本文不以单一 Accuracy 排名直接确定最终模型，而是将多模型比较中的验证集表现作为候选筛选依据，再围绕风险筛查所关注的阳性召回能力进行调参与阈值优化。这样既保留了不同模型的实验对照价值，也使最终决策标准与系统的使用目标保持一致。

B. 最终调优结果

在调参阶段，本文没有直接依据测试集结果选择模型，而是基于验证集表现筛选候选模型并进行 GridSearchCV 调参。本次进入调参的模型为 SVM 和 Logistic Regression。两者交叉验证 ROC AUC 接近；调参完成后，再按照验证集阈值调整后的 F1-score、Recall 和 ROC AUC 选择最终模型。在这一规则下，SVM 在 Recall 和 F1-score 上更优，更符合筛查任务中优先降低漏判风险的目标。

表 V 显示，SVM 在阈值 0.30 下取得 0.8372 的验证集 Recall 和 0.7347 的 F1-score。该阈值体现了风险筛查任务中对假阴性错误的更高敏感性，即在可接受的假阳性增加下尽量减少高风险样本漏判。

表 V
调参候选模型的验证集性能比较

模型	CV AUC	阈值	Recall	F1	AUC
Logistic Regression	0.8421	0.43	0.7209	0.7126	0.8689
SVM	0.8425	0.30	0.8372	0.7347	0.8762

阈值选择严格在验证集上完成，测试集仅用于独立性能评估，以避免根据测试结果反复修改模型而产生信息泄露。从应用角度看，阈值不是固定不变的模型参数，而是与筛查资源和错误代价相关的决策参数：阈值降低通常能够发现更多潜在阳性样本，但也会增加后续复查数量。此外，SVM 输出分数适合用于排序和阈值决策，却不一定等同于经过校准的真实患病概率；已有研究表明，不同分类器的概率估计质量存在明显差异，实际部署前还应使用独立数据评估可靠性并进行概率校准 [12]。

最终选定的 SVM 最佳参数为 $C = 10.0$ 、 $\text{gamma}=0.01$ 、 $\text{class_weight}=\text{None}$ ，验证集分类阈值为 0.30。阈值调整后的最终模型在测试集上的 Accuracy、Precision、Recall、F1-score 和 ROC AUC 分别为 0.7403、0.5972、0.7963、0.6825 和 0.8215。

表 VI 显示，最终模型相较基准模型 Recall 提升 0.0926，F1-score 提升 0.0384，符合减少高风险漏判的筛查目标。同时，ROC AUC 仅提升 0.0061，说明最终收益主要体现在验证集阈值 0.30 对分类决策的调整，而不是模型排序能力的大幅提升。由于当前结果来自一次固定分层划分，这些改进仍需要重复划分、bootstrap 置信区间或统计检验进一步验证稳定性。

表 VI
最终模型与基准模型的测试集性能比较

指标	基准模型	最终模型	变化
Accuracy	0.7273	0.7403	+0.0130
Precision	0.5938	0.5972	+0.0034
Recall	0.7037	0.7963	+0.0926
F1-score	0.6441	0.6825	+0.0384
ROC AUC	0.8154	0.8215	+0.0061

C. 误判与 ROC 分析

基准模型在验证集上的混淆矩阵为：TN=61、FP=19、FN=10、TP=33；在测试集上为：TN=74、FP=26、FN=16、TP=38。如图 6 所示，最终模型在测试集上的混淆矩阵为：TN=71、FP=29、FN=11、TP=43。与基准模型相比，最终模型将测试集假阴性数量由 16 降低到 11，说明阈值优化后的 SVM 能识别更多真实阳性样本；FP 增加则体现了提升 Recall 所付出的 Precision 代价。




图 6. 最终模型在测试集上的混淆矩阵

进一步换算可得，基准模型的假阴性率为 $16/54 = 0.2963$ ，最终模型降至 $11/54 = 0.2037$ ；与此同时，特异度由 $74/100 = 0.7400$ 降至 $71/100 = 0.7100$ 。换言之，模型以增加 3 个假阳性为代价，减少了 5 个假阴性。对于强调尽早识别高风险个体的初筛场景，这一交

换具有实际意义，但若复查成本较高，则仍需结合具体资源重新设定阈值。

图 7 展示了最终模型在测试集上的 ROC 曲线。




图 7. 最终模型在测试集上的 ROC 曲线

最终模型测试集 ROC AUC 为 0.8215，说明其对阳性样本和阴性样本仍具有较好的区分能力。由于 ROC AUC 不依赖单一分类阈值，该指标可以从整体上反映模型区分能力；而 Recall、Precision 和 F1-score 则反映了阈值确定后的实际分类效果。系统采用 0.30 作为分类阈值，主要是为了在保持可接受总体性能的同时提高高风险样本召回率。

值得注意的是，最终模型相较基准模型的 AUC 仅提高 0.0061，而 Recall 提高 0.0926，说明召回改善主要来自模型分数与决策阈值的共同调整，并非排序能力发生同等幅度的提升。因此，ROC 曲线适合评价模型的整体区分能力，混淆矩阵和阈值相关指标则用于判断具体决策规则是否符合筛查目标；两类结果应结合解读 [11]。

D. 特征解释

为兼顾线性基准和最终非线性模型的解释性，本文分别考察 Logistic Regression 的模型系数和 SVM 的 permutation importance。两类结果均表明，Glucose、BMI、Pregnancies、Age 和 DiabetesPedigreeFunction 是较重要的预测变量，其中 Glucose、BMI 和 Age 与相关研究结论基本一致 [9], [10]。

对于阈值优化后的 SVM，本文进一步使用 permutation importance 进行特征重要性分析，结果如图 8 所示。




图 8. 阈值优化后 SVM 的特征重要性 (Permutation Importance)

Permutation importance 衡量打乱某一特征后模型 ROC AUC 的平均下降幅度，因此更适合用于解释非线性模型对不同输入变量的依赖程度。这种基于随机置换评估变量贡献的思想也常用于树模型的模型无关解释 [13]。

最终模型中，Glucose 的重要性均值为 0.155259，明显高于其他特征，说明血糖值是模型进行糖尿病风险判断时最关键的输入因素。BMI、Pregnancies、Age 和 DiabetesPedigreeFunction 也具有较高重要性，这与前文探索性分析和基准模型系数排序基本一致。Insulin、BloodPressure 和 SkinThickness 的重要性相对较低，其中 SkinThickness 的置换重要性均值略为负值，可能与该变量缺失比例较高、填充后信息量有限以及测试集样本量较小有关。负重要性并不表示该特征对糖尿病具有“保护作用”，而表示在当前有限测试样本上，打乱该变量没有稳定降低模型性能。同时，当多个特征相关时，一个特征被置换后，其他相关特征仍可能提供替代信息，从而使重要性被分散或低估；条件置换重要性研究也指出，解释相关变量时需要显式考虑特征间依赖关系 [14]。因此，本节只将重要性结果用于识别模型依赖和生成解释线索，不将其作为变量因果效应或临床诊断依据。特征重要性反映的是模型在当前数据集上的预测依赖，不能直接解释为医学因果关系。

E. 系统演示

本文基于 Gradio 构建了单样本糖尿病风险预测交互式演示系统。系统输入与 Pima 数据集 8 个特征保持一致，并严格复用训练阶段保存的中位数填充器、IQR 裁剪边界、标准化器和最终 SVM 模型。对于 0 值或明显越界的医学指标，系统先返回“输入异常 / 无法评估”提示；通过校验后再输出模型风险分数、低/中/高风险

等级以及简要因素说明。该分数用于排序和风险提示,尚未经过概率校准,不能直接解释为真实患病概率。该系统仅用于风险提示和系统演示,不能替代医学诊断。

VI. 结论、局限性与分工

A. 结论与局限性

在统一预处理和固定数据划分下, SVM 在基础比较中取得最高的 Recall 和 F1-score; 进一步调参后, 阈值为 0.30 的 SVM 在测试集上达到 0.7403 Accuracy、0.7963 Recall、0.6825 F1-score 和 0.8215 ROC AUC。相较 Logistic Regression 基准模型, 最终模型将 Recall 从 0.7037 提升到 0.7963, 并将假阴性数量由 16 降至 11。这说明在当前固定划分和验证集阈值选择下, 阈值优化后的 SVM 更符合减少漏判的风险筛查目标。

本文还基于 Gradio 构建了交互式风险预测系统, 复用训练阶段保存的预处理对象和最终模型, 输出模型风险分数、风险等级和简要因素说明, 并对明显不合理输入进行拦截。该风险分数尚未经过概率校准, 不能直接解释为真实患病概率。局限性在于 Pima 数据集样本量较小、人群范围有限, 且只包含 8 个结构化指标。当前实验未加入重复分层划分、bootstrap 置信区间、统计显著性检验或关键预处理与阈值策略的消融实验, 因此模型优势的稳定性和各流程环节的独立贡献仍需进一步验证。后续可扩大数据来源, 引入更多临床变量, 并尝试概率校准、代价敏感学习、消融实验和 SHAP 等个体级解释方法。

B. 团队分工

本项目按照数据处理、模型训练、参数调优和系统展示进行模块化分工。柯文丽负责数据理解、预处理、数据划分和基准模型; 王佳妮负责模型推理流程封装、Gradio 交互式演示系统和系统集成; 秦琪负责多模型训练、统一评估和性能对比; 何晨东负责超参数调优、最终模型评估和可视化分析。四名成员共同参与报告撰写、结果复核和展示材料整理。

参考文献

- [1] World Health Organization, "Diabetes," Fact sheet, 2024, updated November 2024; available at <https://www.who.int/news-room/fact-sheets/detail/diabetes>.
- [2] M. S. Reza, R. Amin, R. Yasmin, W. Kulsum, and S. Ruhi, "Improving diabetes disease patients classification using stacking ensemble method with PIMA and local healthcare data," *Heliyon*, vol. 10, no. 2, p. e24536, Jan. 2024.
- [3] National Institute of Diabetes and Digestive and Kidney Diseases, "Pima Indians Diabetes Database," Kaggle dataset, n.d., originally attributed to the National Institute of Diabetes and Digestive and Kidney Diseases; available at <https://www.kaggle.com/datasets/uciml/pima-indians-diabetes-database>.
- [4] J. W. Smith, J. Everhart, W. Dickson, W. Knowler, and R. Johannes, "Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus," *Proceedings of the Annual Symposium on Computer Application in Medical Care*, pp. 261–265, Nov. 1988. [Online]. Available: <https://pmc.ncbi.nlm.nih.gov/articles/PMC2245318/>
- [5] D. Sisodia and D. S. Sisodia, "Prediction of Diabetes using Classification Algorithms," *Procedia Computer Science*, vol. 132, pp. 1578–1585, Jan. 2018.
- [6] Q. Zou, K. Qu, Y. Luo, D. Yin, Y. Ju, and H. Tang, "Predicting Diabetes Mellitus With Machine Learning Techniques," *Frontiers in Genetics*, vol. 9, Nov. 2018.
- [7] J. J. Khanam and S. Y. Foo, "A comparison of machine learning algorithms for diabetes prediction," *ICT Express*, vol. 7, no. 4, pp. 432–439, Dec. 2021.
- [8] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems*, vol. 30, Curran Associates, Inc., 2017.
- [9] 李佳思, "基于机器学习的糖尿病预测及 SHAP 特征分析," *智能计算机与应用*, vol. 13, no. 1, pp. 153–157, 2023.
- [10] 成路平, 吴思扬, and 路波, "基于机器学习的 2 型糖尿病发病因素分析与预测," *医学信息学杂志*, vol. 46, no. 9, pp. 17–24, 2025.
- [11] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.
- [12] A. Niculescu-Mizil and R. Caruana, "Predicting good probabilities with supervised learning," in *Proceedings of the 22nd International Conference on Machine Learning*, 2005, pp. 625–632.
- [13] L. Breiman, "Random forests," *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.
- [14] D. Debeer and C. Strobl, "Conditional permutation importance revisited," *BMC Bioinformatics*, vol. 21, p. 307, 2020.