

基于多种机器学习模型的糖尿病风险预测研究

柯文丽，王佳妮，秦琪，何晨东
华东师范大学
计算机科学与技术学院
《机器学习》课程项目

摘要—待补充：摘要。用一段话概括研究问题、数据集、主要方法、最好结果和结论。控制在 150–250 字左右。

Index Terms—待补充：关键词。建议包含：糖尿病预测、Pima Indians Diabetes、机器学习、模型评估、Gradio Demo。

I. 引言

待补充：研究背景。说明糖尿病早期风险预测的意义，以及为什么适合使用机器学习方法。

待补充：项目目标。说明本文围绕 Pima Indians Diabetes 数据集完成风险预测、模型比较和简单 Demo 展示。

待补充：本文贡献。用 2–3 点概括：数据预处理流程、模型训练与评估、系统 Demo 或可解释性分析。

II. 相关工作

待补充：Pima 数据集相关研究。简述已有论文如何使用该数据集进行糖尿病分类和模型比较。

待补充：模型对比研究。占位引用 Logistic Regression、SVM、Random Forest、神经网络、Stacking Ensemble 等方法。

待补充：评价指标与实验设置。占位说明已有研究常用 train-test split、交叉验证、Accuracy、Precision、Recall、F1 和 AUC。

III. 数据集与预处理

A. 数据集来源

待补充：写明 Kaggle / UCI Pima Indians Diabetes 数据集来源、样本数、特征数、标签含义。

B. 特征说明

待补充：放 8 个输入特征的专业表格：英文名、中文含义、单位/医学含义、是否存在不合理 0 值。

C. 缺失值与异常值处理

待补充：说明不合理 0 值处理、中位数填充、IQR 异常值裁剪。注意写清 IQR 边界基于训练集有效观测值计算。

D. 数据划分与标准化

待补充：说明 train/validation/test 划分比例、分层抽样、StandardScaler 标准化，以及避免数据泄露的做法。

E. 图表占位

待补充：放类别分布图、特征分布图、相关性热力图。图片建议来自 figures/class_distribution.png、figures/feature_distribution.png、figures/correlation_heatmap.png。

IV. 方法

A. 整体流程

待补充：放 Pipeline 流程图：Dataset -> Preprocessing -> Split -> Model Training -> Evaluation -> Prediction Demo。

B. 基准模型

待补充：介绍 Logistic Regression baseline，包括 class weight、输入特征和输出概率。

C. 对比模型

待补充：为 KNN、Decision Tree、Random Forest、SVM、XGBoost 或 MLP 预留小段落。后续按实际完成模型保留或删除。

D. 系统 Demo

待补充：介绍 Gradio Demo 的输入、预测结果、风险等级和解释输出。可作为加分创新点。

V. 实验设置

A. 实验环境

待补充：写 Python、scikit-learn、pandas、Gradio、运行环境等。

B. 训练设置

待补充：写统一数据划分、随机种子、模型训练流程、是否使用交叉验证和调参方法。

C. 评价指标

待补充：定义 Accuracy、Precision、Recall、F1-score、ROC AUC。建议用公式或简短文字说明。

D. 超参数设置

待补充：放模型超参数表。未调参模型写默认设置；调参模型写搜索范围和最优参数。

VI. 结果与分析

A. 模型性能对比

待补充：放核心性能对比表：Accuracy、Precision、Recall、F1-score、ROC AUC。先放 baseline，后续补充模型结果。

B. 混淆矩阵与 ROC 曲线

待补充：放最终模型或 baseline 的混淆矩阵、ROC 曲线，并解释误判情况和 AUC 表现。

C. 特征重要性分析

待补充：放特征重要性图。当前可使用 `figures/baseline_feature_importance.png`，后续可替换为 Random Forest 或 XGBoost 特征重要性。

D. Demo 展示

待补充：放低风险和高风险样例截图，说明系统如何输出风险等级、概率和解释。

E. 讨论

待补充：分析模型优缺点、类别不平衡影响、医学解释局限和数据集规模限制。

VII. 结论

待补充：总结最优模型、主要实验发现和项目完成内容。

待补充：说明局限性：数据集样本量有限、特征较少、不能替代医学诊断等。

待补充：后续改进：更多模型调参、交叉验证、SHAP 可解释性、自采数据或更完整 Demo 部署。