

基于多种机器学习模型的糖尿病风险预测研究

柯文丽，王佳妮，秦琪，何晨东

华东师范大学

计算机科学与技术学院

《机器学习》课程项目

摘要—糖尿病风险预测是机器学习在健康管理场景中的典型二分类任务。本文基于 Pima Indians Diabetes Database 构建糖尿病风险预测系统，首先对不合理 0 值、隐式缺失、异常值和特征尺度进行统一处理，并采用分层抽样划分训练集、验证集和测试集。在模型实验阶段，本文以 Logistic Regression 作为基准模型，进一步比较 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM 等多种候选模型。在最终优化阶段，本文基于前序模型比较结果选择候选模型，采用 GridSearchCV 和 5 折 StratifiedKFold 进行超参数调优，并结合验证集 F1、Recall 和 ROC AUC 进行分类阈值选择。最终模型为阈值优化后的 SVM，测试集 Accuracy、Precision、Recall、F1-score 和 ROC AUC 分别为 0.7403、0.5972、0.7963、0.6825 和 0.8215。与 Logistic Regression 基准模型相比，最终模型在 Recall 和 F1-score 上取得提升，更符合问诊筛查场景中减少高风险漏判的目标。本文还基于 Gradio 构建了交互式问诊 Demo，实现单样本风险概率输出、风险等级展示、输入异常校验和简要建议。

Index Terms—糖尿病预测，Pima Indians Diabetes，机器学习，模型比较，超参数调优，ROC AUC，Gradio Demo

I. 引言

糖尿病是一类以慢性高血糖为主要表现的代谢性疾病。长期血糖控制不佳会增加心血管、肾脏、神经和视网膜等并发症风险。Reza 等指出，糖尿病仍是全球重要公共卫生问题，早期诊断和管理有助于预防或延缓并发症发生 [1]。在常规筛查场景中，结构化体检指标比复杂医学检查更容易获取，因此利用机器学习模型进行糖尿病风险预测具有实际意义。

本文使用 Pima Indians Diabetes Database 开展二分类实验。该数据集包含 768 名样本、8 个数值型输入特征和 1 个二分类标签，样本均为至少 21 岁的 Pima Indian 女性 [2]。该数据集规模较小但变量清晰，适合

在统一预处理流程下比较不同分类算法的性能和误判特征。

本文目标是构建一个糖尿病风险预测项目：首先完成缺失值、异常值、标准化和分层划分等数据处理；其次以 Logistic Regression 作为可解释基准，并在统一实验协议下比较 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM 等多种模型；最后通过分类指标、ROC AUC、混淆矩阵和特征解释分析模型表现，并将最终模型接入交互式 Demo。

II. 相关工作

Smith 等较早使用 ADAP 学习算法研究 Pima 数据集上的糖尿病发病预测，并采用敏感性、特异性和 ROC 曲线等临床测试指标进行分析 [3]。Sisodia 等比较了 Decision Tree、SVM 和 Naive Bayes，Zou 等则结合特征降维比较了 Decision Tree、Random Forest 和神经网络；这些工作说明 Pima 数据集常被用于传统分类器和树模型比较 [4], [5]。

Khanam 和 Foo 系统比较了多种机器学习和神经网络模型，并强调缺失值填补、异常值处理、特征选择和归一化会影响最终结果 [6]。Reza 等进一步使用 stacking 方法融合传统机器学习模型和神经网络模型，并比较训练/测试划分与交叉验证协议 [1]。这些研究为本文选择多模型比较、统一预处理和多指标评估提供了依据。

在可解释性方面，Lundberg 和 Lee 提出的 SHAP 方法可通过特征边际贡献解释模型输出 [7]。李佳思和成路平等的研究均指出 Glucose、BMI 和 Age 等变量在糖尿病预测中较为重要 [8], [9]。




图 1. 原始数据集中 Outcome 的类别分布

表 I
PIMA 数据集输入特征说明

特征	含义	单位/说明	0 值处理
Pregnancies	怀孕次数	次	保留
Glucose	口服葡萄糖耐量测试 2 小时血糖浓度	-	缺失
BloodPressure	舒张压	mmHg	缺失
SkinThickness	三头肌皮褶厚度	mm	缺失
Insulin	2 小时血清胰岛素	$\mu\text{U/ml}$	缺失
BMI	身体质量指数	kg/m^2	缺失
DPF	糖尿病家族遗传指数	指数	保留
Age	年龄	岁	保留

III. 数据集与预处理

A. 数据集来源与变量定义

本文使用 Pima Indians Diabetes Database 进行实验。该数据集包含 768 条样本、8 个输入特征和 1 个二分类标签，所有输入特征均为数值型 [2]。标签 Outcome 中，0 表示未检测为糖尿病阳性，1 表示检测为糖尿病阳性。原始数据包含 500 个阴性样本和 268 个阳性样本，阳性样本占比约为 34.9%。图 1 展示了该类别分布。

8 个输入变量的含义见表 I。Pregnancies 的 0 值表示没有怀孕经历，属于合理取值。Glucose、BloodPressure、SkinThickness、Insulin 和 BMI 的 0 值缺乏合理医学含义，因此本文将这些 0 值视作缺失或未测量记录 [1], [6]。

B. 缺失值与异常值处理

原始数据没有显式空值，但存在由不合理 0 值体现的隐式缺失。其中，Glucose 有 5 个 0，BloodPressure

表 II
训练集拟合得到的 IQR 裁剪边界

特征	下界	上界
Pregnancies	0.00	13.50
Glucose	38.75	200.75
BloodPressure	40.00	104.00
SkinThickness	1.00	57.00
Insulin	0.00	355.50
BMI	13.80	50.60
Diabetes Pedigree	0.00	1.2325
Age	0.00	65.25

有 35 个 0，SkinThickness 有 227 个 0，Insulin 有 374 个 0，BMI 有 11 个 0，若直接删除这些样本，会显著减少可用数据。由于中位数比均值更不易受偏态分布和极端值影响，因此，本文先将上述 5 个变量中的不合理 0 值标记为缺失，再使用训练集拟合得到的中位数填充。训练集填充值为 Glucose 117.0、BloodPressure 72.0、SkinThickness 29.0、Insulin 125.0 和 BMI 32.4。

在完成中位数填充后，本文采用 IQR 规则处理异常值。IQR 方法对特征分布形状没有正态性假设，适合 Pima 数据集中偏态较明显的生理指标。对每个特征，仅使用训练集计算第一四分位数 Q_1 、第三四分位数 Q_3 和四分位距

$$IQR = Q_3 - Q_1.$$

下界定义为 $\max(Q_1 - 1.5IQR, 0)$ ，上界定义为 $Q_3 + 1.5IQR$ 。随后使用训练集得到的边界对训练集、验证集和测试集进行一致裁剪，以避免验证集和测试集信息参与参数估计。表 II 给出了最终使用的裁剪边界。

C. 数据划分与标准化

数据划分采用分层抽样，随机种子为 42。首先划分 20% 样本作为测试集，再从剩余样本中划分 20% 作为验证集。最终训练集、验证集和测试集比例约为 64%、16% 和 20%，样本量和类别分布如表 III 所示。由于阳性样本约占 35%，分层抽样可以保持各子集的阳性/阴性比例接近原始数据。验证集用于模型选择和调参，测试集保留作最终评估，以减少调参过程对测试集的过拟合。

标准化使用训练集拟合的均值和标准差完成。Logistic Regression、SVM、KNN 和神经网络等模型对特征尺度敏感，因此统一尺度有助于减少量纲差异对训

表 III
分层划分后的样本量与类别分布

数据集	总样本数	0 类	1 类
训练集	491	320	171
验证集	123	80	43
测试集	154	100	54




图 2. 原始特征分布及不同类别对比

练的影响。验证集、测试集和待预测样本只使用训练集拟合得到的参数进行变换，从而避免数据泄漏。

D. 探索性分析

图 2 展示了各特征在不同标签下的分布，并在存在不合理 0 值的变量上标注 0 值数量。从图中可以看到，阳性样本在 Glucose 和 BMI 上整体更偏向较高取值，Age 和 Pregnancies 也呈现一定右移趋势；同时，SkinThickness 和 Insulin 的 0 值数量明显较多，这与前文将其作为隐式缺失处理的决定一致。

图 3 由原始数据中的全部数值列计算 Pearson 相关系数得到，并用热力图展示特征之间以及特征与标签之间的线性相关程度。从标签 Outcome 对应的相关系数看，Glucose 与标签的相关性最高，约为 0.47；BMI、Age、Pregnancies 和 DiabetesPedigreeFunction 也与标签呈正相关，但强度弱于 Glucose。特征之间的相关性总体不算很高，其中 Pregnancies 与 Age、SkinThickness 与 Insulin、SkinThickness 与 BMI 的相关性相对更明显。这些结果说明血糖、体重相关指标和年龄信息可能对模型预测较有帮助，但相关性只反映线性统计关联，不能直接解释为医学因果关系。




图 3. 原始特征与标签的相关性热力图

IV. 方法与实验设置

A. 整体流程

本文采用统一流程完成模型比较：原始数据先经过缺失值处理、异常值裁剪、标准化和分层划分，随后在相同训练集、验证集和测试集上训练并评估不同模型。验证集用于模型选择和超参数调优，测试集仅用于最终性能报告。图 4 展示了离线实验流程与在线问诊系统推理流程之间的关系。

整体流程可以概括为 Dataset → Preprocessing → Train/Validation/Test Split → Model Training/Tuning → Evaluation → System Demonstration。其中，预处理阶段与第 II 表所述方法保持一致：先将不合理 0 值标记为缺失，再仅基于训练集拟合中位数填充器、IQR 裁剪边界和标准化器。这些预处理参数在训练完成后被保存为独立对象，并在验证、测试和系统预测阶段重复使用。因此，系统端接收到的单条用户输入不会直接进入分类模型，而是先按照训练阶段相同的特征顺序和变换规则完成清洗、裁剪与标准化。该设计能够保证模型训练阶段与系统应用阶段的数据处理逻辑一致，减少由于人工输入原始指标而带来的分布偏移。

在系统展示阶段，本文将实验阶段选定的分类模型与上述预处理对象共同封装。系统界面只负责收集用户输入并展示预测结果，核心预测逻辑由独立的预测模块完成：首先根据 8 个特征构造单样本输入表，随后调用保存的预处理对象完成数据变换，最后由训练好的分类




图 4. 糖尿病风险预测系统总体技术路线

模型输出阳性概率。这种模块化设计将数据处理、模型训练和交互展示解耦，既便于复现实验流程，也便于在模型更新后保持系统界面和推理接口稳定。

B. 模型选择

本文首先使用 Logistic Regression 作为可解释基准模型：设置 `class_weight="balanced"`、最大迭代次数 1000、随机种子 42，并将其作为后续模型比较的参照。在此基础上，多模型比较阶段使用预处理后固定划分的训练集、验证集和测试集，不再重复清洗或重新划分数据。所有候选模型均只在训练集上拟合，并分别在验证集和测试集上使用相同指标进行评估，从而保证不同模型之间以及与 Logistic Regression 基准模型之间的公平可比性。

除 Logistic Regression 基准模型外，实验共纳入 7 个候选模型。KNN 根据邻近样本的距离和投票结果进行分类；Decision Tree 基于特征阈值递归划分样本空间；Random Forest 通过 Bagging 方式集成多棵决策树，以降低单树模型的方差；SVM 通过最大化分类间隔寻找决策边界；Gradient Boosting、XGBoost 和 LightGBM 均属于 Boosting 集成方法，通过逐步拟合前一阶段的误差提升分类性能。表 IV 汇总了基准模型和候选模型的类型及主要设置。

本文采用统一协议计算 Accuracy、Precision、Recall、F1-score 和 ROC AUC。由于糖尿病风险预测属于筛查任务，漏判高风险样本可能使潜在阳性个体错过进一步检查，因此模型比较不能只关注 Accuracy，还应重点观察 Recall 和 F1-score，并结合 ROC AUC 衡量模型对正负样本的整体排序能力。

表 IV
基准模型与候选模型的主要设置

模型	类型	主要设置
Logistic Regression	线性基准模型	<code>class_weight=balanced</code>
KNN	距离型非参数模型	默认参数
Decision Tree	单棵树模型	<code>random_state=42</code> , <code>class_weight=balanced</code>
Random Forest	Bagging 集成模型	<code>n_estimators=100</code> , <code>class_weight=balanced</code>
SVM	最大间隔分类器	<code>probability=True</code> , <code>class_weight=balanced</code>
Gradient Boosting	Boosting 集成模型	<code>random_state=42</code>
XGBoost	梯度提升树模型	<code>eval_metric=logloss</code>
LightGBM	高效梯度提升模型	<code>verbose=-1</code>

C. 超参数调优协议

多模型阶段应使用验证集或交叉验证进行超参数选择。若采用 GridSearchCV 或 RandomizedSearchCV，需要报告搜索范围、交叉验证折数、选择指标和最优参数。对于糖尿病筛查任务，调参时不宜只优化 Accuracy，应同时关注 Recall、F1-score 和 ROC AUC。

最终调参阶段由成员 C 完成。调参脚本读取前序模块输出的 `model_comparison_result.csv`，并结合验证集 ROC AUC、F1-score、Recall 和 Accuracy 筛选进入调参阶段的候选模型。本次实现中，SVM 在基础模型比较阶段具有较高的 Recall 和 F1-score，更符合筛查场景减少漏判的目标；Logistic Regression 则作为可解释基准模型保留用于对照。因此最终调参阶段重点优化 SVM 和 Logistic Regression。

调参采用 GridSearchCV，交叉验证方式为 5 折 StratifiedKfold，划分时设置 `shuffle=True` 和随机种子 42，搜索评分指标为 ROC AUC。Logistic Regression 的搜索空间包括 $C \in \{0.01, 0.1, 1, 10, 100\}$ 、`solver` $\in \{\text{liblinear}, \text{lbfgs}\}$ 、`penalty=l2` 以及 `class_weight` $\in \{\text{None}, \text{balanced}\}$ 。SVM 采用 RBF 核，搜索空间包

括 $C \in \{0.1, 1, 10, 100\}$ 、 $\text{gamma} \in \{\text{scale}, 0.01, 0.1, 1\}$ 以及 $\text{class_weight} \in \{\text{None}, \text{balanced}\}$ 。

在获得每个候选模型的最优超参数后，本文进一步在验证集上搜索分类阈值，阈值范围为 0.25 到 0.75，步长为 0.01。阈值选择以 F1-score 为主要目标，并在可能情况下要求验证集 Recall 不低于 0.70。考虑到问诊筛查任务中漏判阳性样本的代价较高，最终模型选择时采用阈值调整后的验证集 F1-score、Recall 和 ROC AUC 作为排序依据，同时限制训练集和验证集之间的 F1-score 差距，以降低过拟合风险。

最终选择的模型为 SVM，最优参数为 $C = 10.0$ 、 $\text{gamma}=0.01$ 、 $\text{class_weight}=\text{None}$ ，验证集上选择的分类阈值为 0.30。调参结果保存为 `tuning_results.csv`，最优参数和模型选择依据保存为 `best_params.json`，最终模型保存为 `models/best_model.pkl`。

D. 评价指标

糖尿病预测是类别不平衡二分类问题，单一 Accuracy 可能掩盖阳性样本漏判。因此本文纳入了 Accuracy、Precision、Recall、F1-score 和 ROC AUC 作为评价指标。其中 Recall 衡量真实阳性样本被正确识别的比例；在筛查场景中，假阴性意味着潜在高风险个体被漏掉，因此 Recall 和 F1-score 比单纯 Accuracy 更需要关注。ROC AUC 不依赖单一分类阈值，用于衡量模型对阳性样本的概率排序能力。

V. 结果与分析

A. 模型性能比较

表 V 汇总了 Logistic Regression 基准模型以及 7 个候选模型在验证集和测试集上的性能。所有模型使用相同的预处理结果和固定数据划分，并仅使用训练集进行拟合，表中结果可用于比较不同模型在基础参数设置下的表现。

图 5 进一步展示了各模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC。由于糖尿病风险预测不能只关注总体预测正确率，本文在比较候选模型时重点考察 Recall 和 F1-score，并使用 ROC AUC 衡量模型对正负样本的整体排序能力。

在基础参数设置下，SVM 与 XGBoost 的测试集 Accuracy 均为 0.7468，并列所有模型中的最高值。但 SVM 的 Recall 为 0.7778，F1-score 为 0.6829，二者均

为所有候选模型中的最高值。相比 Logistic Regression 基准模型，SVM 的 Recall 从 0.7037 提升至 0.7778，F1-score 从 0.6441 提升至 0.6829。这说明 SVM 能够识别更多阳性样本，在筛查场景下表现出较好的应用潜力。

Random Forest 的测试集 ROC AUC 为 0.8275，是所有模型中的最高值，说明其概率排序能力较好。但其 Recall 仅为 0.5370，低于 SVM 和 Logistic Regression，表明默认分类阈值下仍可能漏判较多阳性样本。该结果说明，Random Forest 具有较好的整体区分能力，但仍需要结合参数优化和阈值调整改善阳性样本识别效果。

XGBoost 的测试集 Accuracy 为 0.7468，Precision 为 0.6596，但 Recall 仅为 0.5741，说明其预测相对保守。LightGBM 的各项指标较为均衡，但没有超过 SVM 的 Recall 和 F1-score，也没有超过 Random Forest 的 ROC AUC。Decision Tree 和 Gradient Boosting 在默认参数下表现相对较弱。综合考虑筛查任务中漏判阳性样本的风险，SVM 和 Random Forest 可作为后续优化阶段的重点候选模型，并结合 Recall、F1-score、ROC AUC 和分类阈值进行综合选择。

B. 最终调优结果

在最终调参阶段，本文没有直接依据测试集结果选择模型，而是基于验证集表现筛选候选模型并进行 GridSearchCV 调参。本次进入调参的模型为 SVM 和 Logistic Regression。调参后，SVM 的最佳参数为 $C = 10.0$ 、 $\text{gamma}=0.01$ 、 $\text{class_weight}=\text{None}$ ，验证集选择得到的分类阈值为 0.30。阈值调整后的最终模型在测试集上的 Accuracy、Precision、Recall、F1-score 和 ROC AUC 分别为 0.7403、0.5972、0.7963、0.6825 和 0.8215。与 Logistic Regression 基准模型相比，最终模型在测试集 Recall 上由 0.7037 提升到 0.7963，F1-score 由 0.6441 提升到 0.6825，ROC AUC 由 0.8154 提升到 0.8215。这表明最终模型更倾向于识别真实阳性样本，符合糖尿病风险问诊系统减少高风险漏判的应用目标。

C. 误判与 ROC 分析

当前基准模型在验证集上的混淆矩阵为：TN=61、FP=19、FN=10、TP=33；在测试集上为：TN=74、FP=26、FN=16、TP=38。从筛查任务角度看，16 个测试集假阴性意味着真实阳性样本被判断为阴性，这是后续模型优化时应重点减少的错误类型。

表 V
模型性能比较表

模型	Val Acc.	Val Prec.	Val Recall	Val F1	Val AUC	Test Acc.	Test Prec.	Test Recall	Test F1	Test AUC
Logistic Regression	0.7642	0.6346	0.7674	0.6947	0.8709	0.7273	0.5938	0.7037	0.6441	0.8154
KNN	0.7805	0.7105	0.6279	0.6667	0.8581	0.7273	0.6154	0.5926	0.6038	0.7675
Decision Tree	0.7886	0.7429	0.6047	0.6667	0.7461	0.6948	0.5714	0.5185	0.5437	0.6543
Random Forest	0.7967	0.7368	0.6512	0.6914	0.8365	0.7338	0.6444	0.5370	0.5859	0.8275
SVM	0.7967	0.6667	0.8372	0.7423	0.8759	0.7468	0.6087	0.7778	0.6829	0.8157
Gradient Boosting	0.7236	0.6098	0.5814	0.5952	0.8311	0.7013	0.5952	0.4630	0.5208	0.7959
XGBoost	0.7561	0.6857	0.5581	0.6154	0.7985	0.7468	0.6596	0.5741	0.6139	0.7967
LightGBM	0.7724	0.6923	0.6279	0.6585	0.8308	0.7273	0.6304	0.5370	0.5800	0.8002




图 5. 不同模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC 对比

表 VI
最终模型与基准模型测试集结果对比

指标	基准模型	最终模型	变化
Accuracy	0.7273	0.7403	+0.0130
Precision	0.5938	0.5972	+0.0034
Recall	0.7037	0.7963	+0.0926
F1-score	0.6441	0.6825	+0.0384
ROC AUC	0.8154	0.8215	+0.0061

最终模型在测试集上的混淆矩阵为：TN=71、FP=29、FN=11、TP=43。与基准模型相比，最终模型将测试集假阴性数量由 16 降低到 11，说明阈值优化后的 SVM 能识别更多真实阳性样本。与此同时，最终模型的 FP 数量为 29，说明模型为提升 Recall 付出了一定 Precision 代价。这种取舍在问诊提醒场景中是可以接受的：系统输出仅用于风险提示和课程展示，并不会直接替代医学诊断。

图 7 展示了最终模型在测试集上的 ROC 曲线。最终模型测试集 ROC AUC 为 0.8215，说明其对阳性样




图 6. 最终模型在测试集上的混淆矩阵

本和阴性样本仍具有较好的概率排序能力。由于 ROC AUC 不依赖单一分类阈值，该指标可以从整体上反映




图 7. 最终模型在测试集上的 ROC 曲线




图 8. Logistic Regression 基准模型特征影响排序

模型区分能力；而 Recall、Precision 和 F1-score 则反映了阈值确定后的实际分类效果。本文在最终系统中采用 0.30 作为分类阈值，主要是为了在保持可接受总体性能的同时提高高风险样本召回率。

D. 特征解释

当前可用的解释结果来自 Logistic Regression 基准模型。图 8 展示了标准化系数绝对值排序。Glucose、BMI、DiabetesPedigreeFunction、Pregnancies 和 Age 位于前五位；其中 Glucose、BMI 和 Age 与相关研究中强调的重要因素基本一致 [8], [9]。需要注意的是，线性模型系数只反映当前数据划分和模型假设下的统计关联，不能解释为医学因果关系。




图 9. 最终模型特征重要性 (Permutation Importance)

在最终模型解释阶段，本文进一步使用 permutation importance 对阈值优化后的 SVM 进行特征重要性分析，结果如图 9 所示。Permutation importance 衡量打乱某一特征后模型 ROC AUC 的平均下降幅度，因此更适合用于解释非线性模型对不同输入变量的依赖程度。

最终模型中，Glucose 的重要性均值为 0.155259，明显高于其他特征，说明血糖值是模型进行糖尿病风险判断时最关键的输入因素。BMI、Pregnancies、Age 和 DiabetesPedigreeFunction 也具有较高重要性，这与前文探索性分析和基准模型系数排序基本一致。Insulin、BloodPressure 和 SkinThickness 的重要性相对较低，其中 SkinThickness 的置换重要性均值略为负值，可能与该变量缺失比例较高、填充后信息量有限以及测试集样本量较小有关。需要强调的是，特征重要性反映模型在当前数据集上的预测依赖，不能直接解释为医学因果关系。

E. 系统演示

为展示模型在单样本预测场景中的应用效果，本文进一步构建了基于 Gradio 的糖尿病风险预测问诊系统。系统输入与 Pima 数据集的 8 个特征保持一致，包括 Pregnancies、Glucose、BloodPressure、SkinThickness、Insulin、BMI、DiabetesPedigreeFunction 和 Age。在交互界面中，这些变量被转换为易于理解的中文表单项，用户可以根据个体情况填写或调整相应数值。系统同时保留典型样例入口，用于在展示时快速说明低风险和高风险输入在模型输出上的差异。

系统预测流程严格复用实验阶段的预处理协议。对于网页端提交的原始指标，系统首先检查输入范围。当

血糖、血压、BMI、皮肤厚度、胰岛素等关键医学指标为 0 或明显超出合理范围时，系统会返回“输入异常 / 无法评估”，并提示用户修正输入，而不会输出看似精确的风险概率。通过输入校验后，系统再按照训练阶段的规则处理不合理 0 值，使用训练集拟合得到的中位数填充器、IQR 裁剪边界和标准化器进行变换。完成预处理后，样本被送入最终 SVM 模型，模型输出糖尿病阳性的预测概率。由于预处理对象和模型对象均由训练阶段保存得到，系统端推理与离线实验保持了相同的特征顺序和数据变换方式，从而提高了系统展示结果与实验结果之间的一致性。

系统输出由三部分组成。第一部分是阳性预测概率，用于表示模型认为该输入样本属于糖尿病阳性类别的可能性；第二部分是风险等级，本文按概率阈值将低于 0.35 的样本标记为低风险，将位于 [0.35, 0.65) 的样本标记为中风险，将不低于 0.65 的样本标记为高风险；第三部分是简要解释和建议文本，用于提示血糖、BMI、年龄、血压或糖尿病家族遗传指数等较突出的输入因素，并给出生活方式或就医检查建议。因此，系统展示并不只给出二分类标签，而是同时呈现概率、等级、输入因素说明和风险建议，使预测结果更适合课程展示和非技术用户理解。

该系统仅用于机器学习课程项目展示，其输出不能替代医生诊断或真实临床决策。

VI. 结论、局限性与分工

A. 结论与局限性

在统一预处理和固定数据划分下，多模型比较结果表明，SVM 在测试集上的 Recall 和 F1-score 分别达到 0.7778 和 0.6829，均为基础候选模型中的最高值；Random Forest 的 ROC AUC 达到 0.8275，体现出较好的概率排序能力。XGBoost 的 Accuracy 为 0.7468，与 SVM 持平，但 Recall 和 F1-score 低于 SVM。Decision Tree 和 Gradient Boosting 在默认参数下表现相对较弱。

上述结果说明，糖尿病风险预测不能只依据 Accuracy 选择模型。由于漏判高风险样本可能使潜在阳性个体错过进一步检查，模型选择应综合考虑 Recall、F1-score、ROC AUC 和分类阈值。基于前序模型比较结果，最终调参阶段选择 SVM 和 Logistic Regression 作为候选模型进行 GridSearchCV 搜索。最终模型为阈值优化后的 SVM，最优参数为 $C = 10.0$ 、 $\gamma = 0.01$ 、

表 VII
团队成员分工

成员	主要负责内容
柯文丽	数据理解、数据预处理、数据划分与基准模型
王佳妮	交互式问诊系统设计、模型推理流程封装、系统集成
秦琪	多模型训练、模型性能对比与结果整理
何晨东	参数调优、最终模型评估与结果可视化分析

$\text{class_weight}=\text{None}$ ，并在验证集上选择 0.30 作为分类阈值。该模型在测试集上取得 0.7403 的 Accuracy、0.5972 的 Precision、0.7963 的 Recall、0.6825 的 F1-score 和 0.8215 的 ROC AUC。相较于 Logistic Regression 基准模型，最终模型将测试集 Recall 从 0.7037 提升到 0.7963，F1-score 从 0.6441 提升到 0.6825，同时将假阴性数量由 16 降低到 11。

系统展示方面，本文基于 Gradio 构建了糖尿病风险预测问诊 Demo。Demo 优先加载最终模型 `models/best_model.pkl`，并复用训练阶段保存的预处理对象完成单样本推理。系统不仅输出风险概率和低/中/高风险等级，还增加了输入异常校验、单位与范围提示、关键因素解释和生活/就医建议。当用户输入明显不合理的医学指标时，系统会提示“输入异常 / 无法评估”，避免对无效输入给出误导性风险概率。

本文仍存在若干局限。首先，Pima 数据集样本量有限，且样本人群限定为至少 21 岁的 Pima Indian 女性，模型结论不宜直接推广到其他人群。其次，数据仅包含 8 个结构化生理指标，缺少饮食、运动、用药史等更完整的临床信息。最后，项目模型只能用于课程实验和风险提示，不能作为医学诊断工具。

后续工作可进一步扩大数据规模，并引入饮食、运动、用药史、既往检查结果等更丰富的临床变量。此外，还可使用概率校准、代价敏感学习或更细粒度的阈值策略，在控制漏判风险的同时平衡 Precision 和 Recall。对于模型解释，可以进一步引入 SHAP 等个体级解释方法，使系统能够给出更具体的单样本特征贡献说明。最后，还应继续完善 Demo 部署和用户测试，提高系统在课程展示和实际交互中的稳定性。

B. 团队分工

本项目采用模块化分工方式完成。柯文丽主要负责数据集字段理解、缺失值与异常值处理、特征标准化以及训练集和测试集划分，并建立基准模型；秦琪负责训

练多种机器学习模型，并从 Accuracy、Precision、Recall、F1 和 AUC 等指标对不同模型进行比较；何晨东负责对候选模型进行参数调优，完成最终模型评估，并绘制混淆矩阵、ROC 曲线和特征重要性等结果图；王佳妮负责系统集成与 Demo 展示部分：设计 Gradio 交互式问诊界面，将用户输入、预处理对象和模型推理流程封装为统一预测接口，实现单样本风险概率输出、低/中/高风险等级划分和输入因素解释；同时整理系统运行方式、模型接入约定和系统演示相关报告内容，保证训练阶段得到的模型能够以可交互形式展示。各成员同时参与对应模块的报告与展示内容整理。

参考文献

- [1] M. S. Reza, R. Amin, R. Yasmin, W. Kulsum, and S. Ruhi, "Improving diabetes disease patients classification using stacking ensemble method with PIMA and local healthcare data," *Heliyon*, vol. 10, no. 2, p. e24536, Jan. 2024.
- [2] National Institute of Diabetes and Digestive and Kidney Diseases, "Pima Indians Diabetes Database," UCI Machine Learning Repository, 1990, dataset description; 768 instances, 8 attributes plus class.
- [3] J. W. Smith, J. Everhart, W. Dickson, W. Knowler, and R. Johannes, "Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus," *Proceedings of the Annual Symposium on Computer Application in Medical Care*, pp. 261–265, Nov. 1988.
- [4] D. Sisodia and D. S. Sisodia, "Prediction of Diabetes using Classification Algorithms," *Procedia Computer Science*, vol. 132, pp. 1578–1585, Jan. 2018.
- [5] Q. Zou, K. Qu, Y. Luo, D. Yin, Y. Ju, and H. Tang, "Predicting Diabetes Mellitus With Machine Learning Techniques," *Frontiers in Genetics*, vol. 9, Nov. 2018.
- [6] J. J. Khanam and S. Y. Foo, "A comparison of machine learning algorithms for diabetes prediction," *ICT Express*, vol. 7, no. 4, pp. 432–439, Dec. 2021.
- [7] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems*, vol. 30. Curran Associates, Inc., 2017.
- [8] 李佳思, "基于机器学习的糖尿病预测及 SHAP 特征分析," *智能计算机与应用*, vol. 13, no. 1, pp. 153–157, 2023.
- [9] 成路平, 吴思扬, and 路波, "基于机器学习的 2 型糖尿病发病因素分析与预测," *医学信息学杂志*, vol. 46, no. 9, pp. 17–24, 2025.