

基于多种机器学习模型的糖尿病风险预测研究

柯文丽, 王佳妮, 秦琪, 何晨东
华东师范大学
计算机科学与技术学院
《机器学习》课程项目

摘要—待补充: 多模型训练完成后补写摘要。摘要应在一段话中概括研究问题、Pima Indians Diabetes 数据集、比较的模型、最佳模型及其关键指标、Gradio Demo 和主要结论。当前已有 Logistic Regression 基准结果, 不要把基准模型写成最终最佳模型。

Index Terms—待补充: 关键词。建议包含: 糖尿病预测、Pima Indians Diabetes、机器学习、模型比较、ROC AUC、Gradio Demo。

I. 引言

糖尿病是一类以慢性高血糖为主要表现的代谢性疾病。长期血糖控制不佳会增加心血管、肾脏、神经和视网膜等并发症风险。Reza 等指出, 糖尿病仍是全球重要公共卫生问题, 早期诊断和管理有助于预防或延缓并发症发生 [1]。在常规筛查场景中, 结构化体检指标比复杂医学检查更容易获取, 因此利用机器学习模型进行糖尿病风险预测具有实际意义。

本文使用 Pima Indians Diabetes Database 开展二分类实验。该数据集包含 768 名样本、8 个数值型输入特征和 1 个二分类标签, 样本均为至少 21 岁的 Pima Indian 女性 [2]。该数据集规模较小但变量清晰, 适合在统一预处理流程下比较不同分类算法的性能和误判特征。

本文目标是构建一个糖尿病风险预测项目: 首先完成缺失值、异常值、标准化和分层划分等数据处理; 其次以 Logistic Regression 作为可解释基准, 并在统一实验协议下比较 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM 等多种模型; 最后通过分类指标、ROC AUC、混淆矩阵和特征解释分析模型表现, 并将最终模型接入交互式 Demo。

II. 相关工作

Smith 等较早使用 ADAP 学习算法研究 Pima 数据集上的糖尿病发病预测, 并采用敏感性、特异性和 ROC 曲线等临床测试指标进行分析 [3]。Sisodia 等比较了 Decision Tree、SVM 和 Naive Bayes, Zou 等则结合特征降维比较了 Decision Tree、Random Forest 和神经网络; 这些工作说明 Pima 数据集常被用于传统分类器和树模型比较 [4], [5]。

Khanam 和 Foo 系统比较了多种机器学习和神经网络模型, 并强调缺失值填补、异常值处理、特征选择和归一化会影响最终结果 [6]。Reza 等进一步使用 stacking 方法融合传统机器学习模型和神经网络模型, 并比较训练/测试划分与交叉验证协议 [1]。这些研究为本文选择多模型比较、统一预处理和多指标评估提供了依据。

在可解释性方面, Lundberg 和 Lee 提出的 SHAP 方法可通过特征边际贡献解释模型输出 [7]。李佳思和成路平等的研究均指出 Glucose、BMI 和 Age 等变量在糖尿病预测中较为重要 [8], [9]。

III. 数据集与预处理

A. 数据集来源与变量定义

本文使用 Pima Indians Diabetes Database 进行实验。该数据集包含 768 条样本、8 个输入特征和 1 个二分类标签, 所有输入特征均为数值型 [2]。标签 Outcome 中, 0 表示未检测为糖尿病阳性, 1 表示检测为糖尿病阳性。原始数据包含 500 个阴性样本和 268 个阳性样本, 阳性样本占比约为 34.9%。图 1 展示了该类别分布。

8 个输入变量的含义见表 I。Pregnancies 的 0 值表示没有怀孕经历, 属于合理取值。Glucose、




图 1. 原始数据集中 Outcome 的类别分布

表 I
PIMA 数据集输入特征说明

特征	含义	单位/说明	0 值处理
Pregnancies	怀孕次数	次	保留
Glucose	口服葡萄糖耐量测试 2 小时血糖浓度	-	缺失
BloodPressure	舒张压	mmHg	缺失
SkinThickness	三头肌皮褶厚度	mm	缺失
Insulin	2 小时血清胰岛素	$\mu\text{U/ml}$	缺失
BMI	身体质量指数	kg/m^2	缺失
DPF	糖尿病家族遗传指数	指数	保留
Age	年龄	岁	保留

BloodPressure、SkinThickness、Insulin 和 BMI 的 0 值缺乏合理医学含义，因此本文将这些 0 值视作缺失或未测量记录 [1], [6]。

B. 缺失值与异常值处理

原始数据没有显式空值，但存在由不合理 0 值体现的隐式缺失。其中，Glucose 有 5 个 0，BloodPressure 有 35 个 0，SkinThickness 有 227 个 0，Insulin 有 374 个 0，BMI 有 11 个 0，若直接删除这些样本，会显著减少可用数据。由于中位数比均值更不易受偏态分布和极端值影响，因此，本文先将上述 5 个变量中的不合理 0 值标记为缺失，再使用训练集拟合得到的中位数填充。训练集填充值为 Glucose 117.0、BloodPressure 72.0、SkinThickness 29.0、Insulin 125.0 和 BMI 32.4。

在完成中位数填充后，本文采用 IQR 规则处理异常值。IQR 方法对特征分布形状没有正态性假设，适合 Pima 数据集中偏态较明显的生理指标。对每个特征，仅

表 II
训练集拟合得到的 IQR 裁剪边界

特征	下界	上界
Pregnancies	0.00	13.50
Glucose	38.75	200.75
BloodPressure	40.00	104.00
SkinThickness	1.00	57.00
Insulin	0.00	355.50
BMI	13.80	50.60
Diabetes Pedigree	0.00	1.2325
Age	0.00	65.25

表 III
分层划分后的样本量与类别分布

数据集	总样本数	0 类	1 类
训练集	491	320	171
验证集	123	80	43
测试集	154	100	54

使用训练集计算第一四分位数 Q_1 、第三四分位数 Q_3 和四分位距

$$IQR = Q_3 - Q_1.$$

下界定义为 $\max(Q_1 - 1.5IQR, 0)$ ，上界定义为 $Q_3 + 1.5IQR$ 。随后使用训练集得到的边界对训练集、验证集和测试集进行一致裁剪，以避免验证集和测试集信息参与参数估计。表 II 给出了最终使用的裁剪边界。

C. 数据划分与标准化

数据划分采用分层抽样，随机种子为 42。首先划分 20% 样本作为测试集，再从剩余样本中划分 20% 作为验证集。最终训练集、验证集和测试集比例约为 64%、16% 和 20%，样本量和类别分布如表 III 所示。由于阳性样本约占 35%，分层抽样可以保持各子集的阳性/阴性比例接近原始数据。验证集用于模型选择和调参，测试集保留作最终评估，以减少调参过程对测试集的过拟合。

标准化使用训练集拟合的均值和标准差完成。Logistic Regression、SVM、KNN 和神经网络等模型对特征尺度敏感，因此统一尺度有助于减少量纲差异对训练的影响。验证集、测试集和待预测样本只使用训练集拟合得到的参数进行变换，从而避免数据泄漏。

D. 探索性分析

图 2 展示了各特征在不同标签下的分布，并在存在不合理 0 值的变量上标注 0 值数量。从图中可以

IV. 方法与实验设置

A. 整体流程

本文采用统一流程完成模型比较：原始数据先经过缺失值处理、异常值裁剪、标准化和分层划分，随后在相同训练集、验证集和测试集上训练并评估不同模型。验证集用于模型选择和超参数调优，测试集仅用于最终性能报告。图 4 展示了离线实验流程与在线问诊系统推理流程之间的关系。

整体流程可以概括为 Dataset → Preprocessing → Train/Validation/Test Split → Model Training/Tuning → Evaluation → System Demonstration。其中，预处理阶段与第 II 表所述方法保持一致：先将不合理 0 值标记为缺失，再仅基于训练集拟合中位数填充器、IQR 裁剪边界和标准化器。这些预处理参数在训练完成后被保存为独立对象，并在验证、测试和系统预测阶段重复使用。因此，系统端接收到的单条用户输入不会直接进入分类模型，而是先按照训练阶段相同的特征顺序和变换规则完成清洗、裁剪与标准化。该设计能够保证模型训练阶段与系统应用阶段的数据处理逻辑一致，减少由于人工输入原始指标而带来的分布偏移。

在系统展示阶段，本文将实验阶段选定的分类模型与上述预处理对象共同封装。系统界面只负责收集用户输入并展示预测结果，核心预测逻辑由独立的预测模块完成：首先根据 8 个特征构造单样本输入表，随后调用保存的预处理对象完成数据变换，最后由训练好的分类模型输出阳性概率。这种模块化设计将数据处理、模型训练和交互展示解耦，既便于复现实验流程，也便于在模型更新后保持系统界面和推理接口稳定。

B. 模型选择

本文首先使用 Logistic Regression 作为可解释基准模型：设置 `class_weight="balanced"`、最大迭代次数 1000、随机种子 42，并将其作为后续模型比较的参照。在此基础上，多模型比较阶段使用预处理后固定划分的训练集、验证集和测试集，不再重复清洗或重新划分数据。所有候选模型均只在训练集上拟合，并分别在验证集和测试集上使用相同指标进行评估，从而保证不同模型之间以及与 Logistic Regression 基准模型之间的公平可比性。

除 Logistic Regression 基准模型外，实验共纳入 7 个候选模型。KNN 根据邻近样本的距离和投票结果进




图 2. 原始特征分布及不同类别对比




图 3. 原始特征与标签的相关性热力图

看到，阳性样本在 Glucose 和 BMI 上整体更偏向较高取值，Age 和 Pregnancies 也呈现一定右移趋势；同时，SkinThickness 和 Insulin 的 0 值数量明显较多，这与前文将其作为隐式缺失处理的决定一致。

图 3 由原始数据中的全部数值列计算 Pearson 相关系数得到，并用热力图展示特征之间以及特征与标签之间的线性相关程度。从标签 Outcome 对应的相关系数看，Glucose 与标签的相关性最高，约为 0.47；BMI、Age、Pregnancies 和 DiabetesPedigreeFunction 也与标签呈正相关，但强度弱于 Glucose。特征之间的相关性总体不算很高，其中 Pregnancies 与 Age、SkinThickness 与 Insulin、SkinThickness 与 BMI 的相关性相对更明显。这些结果说明血糖、体重相关指标和年龄信息可能对模型预测较有帮助，但相关性只反映线性统计关联，不能直接解释为医学因果关系。




图 4. 糖尿病风险预测系统总体技术路线

表 IV
基准模型与候选模型的主要设置

模型	类型	主要设置
Logistic Regression	线性基准模型	<code>class_weight=balanced</code>
KNN	距离型非参数模型	默认参数
Decision Tree	单棵树模型	<code>random_state=42,</code> <code>class_weight=balanced</code>
Random Forest	Bagging 集成模型	<code>n_estimators=100,</code> <code>class_weight=balanced</code>
SVM	最大间隔分类器	<code>probability=True,</code> <code>class_weight=balanced</code>
Gradient Boosting	Boosting 集成模型	<code>random_state=42</code>
XGBoost	梯度提升树模型	<code>eval_metric=logloss</code>
LightGBM	高效梯度提升模型	<code>verbose=-1</code>

行分类；Decision Tree 基于特征阈值递归划分样本空间；Random Forest 通过 Bagging 方式集成多棵决策树，以降低单树模型的方差；SVM 通过最大化分类间隔寻找决策边界；Gradient Boosting、XGBoost 和 LightGBM 均属于 Boosting 集成方法，通过逐步拟合前一阶段的误差提升分类性能。表 IV 汇总了基准模型和候选模型的类型及主要设置。

本文采用统一协议计算 Accuracy、Precision、Recall、F1-score 和 ROC AUC。由于糖尿病风险预测属于筛查任务，漏判高风险样本可能使潜在阳性个体错过进一步检查，因此模型比较不能只关注 Accuracy，还应重点观察 Recall 和 F1-score，并结合 ROC AUC 衡量模型对正负样本的整体排序能力。

C. 超参数调优协议

多模型阶段应使用验证集或交叉验证进行超参数选择。若采用 GridSearchCV 或 RandomizedSearchCV，需要报告搜索范围、交叉验证折数、选择指标和最优参数。对于糖尿病筛查任务，调参时不宜只优化 Accuracy，应同时关注 Recall、F1-score 和 ROC AUC。

待补充：补充实际调参方法和搜索空间。例如 KNN 的邻居数、SVM 的 C 和 γ 、Random Forest 的树数量和深度等。

D. 评价指标

糖尿病预测是类别不平衡二分类问题，单一 Accuracy 可能掩盖阳性样本漏判。因此本文纳入了 Accuracy、Precision、Recall、F1-score 和 ROC AUC 作为评价指标。其中 Recall 衡量真实阳性样本被正确识别的比例；在筛查场景中，假阴性意味着潜在高风险个体被漏掉，因此 Recall 和 F1-score 比单纯 Accuracy 更需要关注。ROC AUC 不依赖单一分类阈值，用于衡量模型对阳性样本的概率排序能力。

V. 结果与分析

A. 模型性能比较

表 V 汇总了 Logistic Regression 基准模型以及 7 个候选模型在验证集和测试集上的性能。所有模型使用相同的预处理结果和固定数据划分，并仅使用训练集进行拟合，表中结果可用于比较不同模型在基础参数设置下的表现。

图 5 进一步展示了各模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC。由于糖尿病风险预测不能只关注总体预测正确率，本文在比较候选模型时重点考察 Recall 和 F1-score，并使用 ROC AUC 衡量模型对正负样本的整体排序能力。

在基础参数设置下，SVM 与 XGBoost 的测试集 Accuracy 均为 0.7468，并列所有模型中的最高值。但 SVM 的 Recall 为 0.7778，F1-score 为 0.6829，二者均为所有候选模型中的最高值。相比 Logistic Regression 基准模型，SVM 的 Recall 从 0.7037 提升至 0.7778，F1-

表 V
模型性能比较表

模型	Val Acc.	Val Prec.	Val Recall	Val F1	Val AUC	Test Acc.	Test Prec.	Test Recall	Test F1	Test AUC
Logistic Regression	0.7642	0.6346	0.7674	0.6947	0.8709	0.7273	0.5938	0.7037	0.6441	0.8154
KNN	0.7805	0.7105	0.6279	0.6667	0.8581	0.7273	0.6154	0.5926	0.6038	0.7675
Decision Tree	0.7886	0.7429	0.6047	0.6667	0.7461	0.6948	0.5714	0.5185	0.5437	0.6543
Random Forest	0.7967	0.7368	0.6512	0.6914	0.8365	0.7338	0.6444	0.5370	0.5859	0.8275
SVM	0.7967	0.6667	0.8372	0.7423	0.8759	0.7468	0.6087	0.7778	0.6829	0.8157
Gradient Boosting	0.7236	0.6098	0.5814	0.5952	0.8311	0.7013	0.5952	0.4630	0.5208	0.7959
XGBoost	0.7561	0.6857	0.5581	0.6154	0.7985	0.7468	0.6596	0.5741	0.6139	0.7967
LightGBM	0.7724	0.6923	0.6279	0.6585	0.8308	0.7273	0.6304	0.5370	0.5800	0.8002




图 5. 不同模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC 对比

score 从 0.6441 提升至 0.6829。这说明 SVM 能够识别更多阳性样本，在筛查场景下表现出较好的应用潜力。

Random Forest 的测试集 ROC AUC 为 0.8275，是所有模型中的最高值，说明其概率排序能力较好。但其 Recall 仅为 0.5370，低于 SVM 和 Logistic Regression，表明默认分类阈值下仍可能漏判较多阳性样本。该结果说明，Random Forest 具有较好的整体区分能力，但仍需要结合参数优化和阈值调整改善阳性样本识别效果。

XGBoost 的测试集 Accuracy 为 0.7468，Precision 为 0.6596，但 Recall 仅为 0.5741，说明其预测相对保守。LightGBM 的各项指标较为均衡，但没有超过 SVM 的 Recall 和 F1-score，也没有超过 Random Forest 的 ROC AUC。Decision Tree 和 Gradient Boosting 在默认参数下表现相对较弱。综合考虑筛查任务中漏判阳性样本的风险，SVM 和 Random Forest 可作为后续优化阶段的重点候选模型，并结合 Recall、F1-score、ROC AUC 和分类阈值进行综合选择。

B. 误判与 ROC 分析

当前基准模型在验证集上的混淆矩阵为：TN=61、FP=19、FN=10、TP=33；在测试集上为：TN=74、FP=26、FN=16、TP=38。从筛查任务角度看，16 个测试集假阴性意味着真实阳性样本被判断为阴性，这是后续模型优化时应重点减少的错误类型。

待补充：补充最佳模型的混淆矩阵热力图和 ROC 曲线。如果已生成多模型 ROC 曲线，可在此比较各模型 AUC 和曲线形态。

C. 特征解释

当前可用的解释结果来自 Logistic Regression 基准模型。图 6 展示了标准化系数绝对值排序。Glucose、BMI、DiabetesPedigreeFunction、Pregnancies 和 Age 位于前五位；其中 Glucose、BMI 和 Age 与相关研究中强调的重要因素基本一致 [8], [9]。需要注意的是，线性模型系数只反映当前数据划分和模型假设下的统计关联，不能解释为医学因果关系。




图 6. Logistic Regression 基准模型特征影响排序

待补充：若最终模型为 Random Forest、XGBoost 或其他非线性模型，在此替换或补充特征重要性、置换重要性或 SHAP 图。

D. 系统演示

为展示模型在单样本预测场景中的应用效果，本文进一步构建了基于 Gradio 的糖尿病风险预测问诊系统。系统输入与 Pima 数据集的 8 个特征保持一致，包括 Pregnancies、Glucose、BloodPressure、SkinThickness、Insulin、BMI、DiabetesPedigreeFunction 和 Age。在交互界面中，这些变量被转换为易于理解的中文表单项，用户可以根据个体情况填写或调整相应数值。系统同时保留典型样例入口，用于在展示时快速说明低风险和高风险输入在模型输出上的差异。

系统预测流程严格复用实验阶段的预处理协议。对于网页端提交的原始指标，系统首先按照训练阶段的规则处理不合理 0 值，再使用训练集拟合得到的中位数填充器、IQR 裁剪边界和标准化器进行变换。完成预处理后，样本被送入实验阶段选定的分类模型，模型输出糖尿病阳性的预测概率。由于预处理对象和模型对象均由训练阶段保存得到，系统端推理与离线实验保持了相同的特征顺序和数据变换方式，从而提高了系统展示结果与实验结果之间的一致性。

系统输出由三部分组成。第一部分是阳性预测概率，用于表示模型认为该输入样本属于糖尿病阳性类别的可能性；第二部分是风险等级，本文按概率阈值将低于 0.35 的样本标记为低风险，将位于 [0.35, 0.65) 的样本标记为中风险，将不低于 0.65 的样本标记为高风险；第三部分是简要解释文本，用于提示血糖、BMI、年龄、

血压或糖尿病家族遗传指数等较突出的输入因素。因此，系统展示并不只给出二分类标签，而是同时呈现概率、等级和输入因素说明，使预测结果更适合课程展示和非技术用户理解。

该系统仅用于机器学习课程项目展示，其输出不能替代医生诊断或真实临床决策。

VI. 结论、局限性与分工

A. 结论与局限性

在统一预处理和固定数据划分下，多模型比较结果表明，SVM 在测试集上的 Recall 和 F1-score 分别达到 0.7778 和 0.6829，均为基础候选模型中的最高值；Random Forest 的 ROC AUC 达到 0.8275，体现出较好的概率排序能力。XGBoost 的 Accuracy 为 0.7468，与 SVM 持平，但 Recall 和 F1-score 低于 SVM。Decision Tree 和 Gradient Boosting 在默认参数下表现相对较弱。

上述结果说明，糖尿病风险预测不能只依据 Accuracy 选择模型。由于漏判高风险样本可能使潜在阳性个体错过进一步检查，模型选择应综合考虑 Recall、F1-score、ROC AUC 和分类阈值。本阶段的比较结果为后续调参和最终模型选择提供了依据：SVM 和 Random Forest 可作为重点优化对象，XGBoost 和 LightGBM 则可作为备选增强模型。

本文仍存在若干局限。首先，Pima 数据集样本量有限，且样本人群限定为至少 21 岁的 Pima Indian 女性，模型结论不宜直接推广到其他人群。其次，数据仅包含 8 个结构化生理指标，缺少饮食、运动、用药史等更完整的临床信息。最后，项目模型只能用于课程实验和风险提示，不能作为医学诊断工具。

后续工作可围绕候选模型开展交叉验证和超参数搜索，并结合验证集调整分类阈值，在控制漏判风险的同时平衡 Precision 和 Recall。此外，还可引入 SHAP 或置换重要性解释非线性模型，收集更丰富的临床变量，并继续完善 Demo 部署和用户测试。

B. 团队分工

本项目采用模块化分工方式完成。柯文丽主要负责数据集字段理解、缺失值与异常值处理、特征标准化以及训练集和测试集划分，并建立基准模型；秦琪负责训练多种机器学习模型，并从 Accuracy、Precision、Recall、F1 和 AUC 等指标对不同模型进行比较；何晨东负责对

表 VI
团队成员分工

成员	主要负责内容
柯文丽	数据理解、数据预处理、数据划分与基准模型
王佳妮	交互式问诊系统设计、模型推理流程封装、系统集成
秦琪	多模型训练、模型性能对比与结果整理
何晨东	参数调优、最终模型评估与结果可视化分析

候选模型进行参数调优，完成最终模型评估，并绘制混淆矩阵、ROC 曲线和特征重要性等结果图；王佳妮负责系统集成与 Demo 展示部分：设计 Gradio 交互式问诊界面，将用户输入、预处理对象和模型推理流程封装为统一预测接口，实现单样本风险概率输出、低/中/高风险等级划分和输入因素解释；同时整理系统运行方式、模型接入约定和系统演示相关报告内容，保证训练阶段得到的模型能够以可交互形式展示。各成员同时参与对应模块的报告与展示内容整理。

参考文献

- [1] M. S. Reza, R. Amin, R. Yasmin, W. Kulsum, and S. Ruhi, "Improving diabetes disease patients classification using stacking ensemble method with PIMA and local healthcare data," *Heliyon*, vol. 10, no. 2, p. e24536, Jan. 2024.
- [2] National Institute of Diabetes and Digestive and Kidney Diseases, "Pima Indians Diabetes Database," UCI Machine Learning Repository, 1990, dataset description; 768 instances, 8 attributes plus class.
- [3] J. W. Smith, J. Everhart, W. Dickson, W. Knowler, and R. Johannes, "Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus," *Proceedings of the Annual Symposium on Computer Application in Medical Care*, pp. 261–265, Nov. 1988.
- [4] D. Sisodia and D. S. Sisodia, "Prediction of Diabetes using Classification Algorithms," *Procedia Computer Science*, vol. 132, pp. 1578–1585, Jan. 2018.
- [5] Q. Zou, K. Qu, Y. Luo, D. Yin, Y. Ju, and H. Tang, "Predicting Diabetes Mellitus With Machine Learning Techniques," *Frontiers in Genetics*, vol. 9, Nov. 2018.
- [6] J. J. Khanam and S. Y. Foo, "A comparison of machine learning algorithms for diabetes prediction," *ICT Express*, vol. 7, no. 4, pp. 432–439, Dec. 2021.
- [7] S. M. Lundberg and S.-I. Lee, "A Unified Approach to Interpreting Model Predictions," in *Advances in Neural Information Processing Systems*, vol. 30. Curran Associates, Inc., 2017.
- [8] 李佳思, "基于机器学习的糖尿病预测及 SHAP 特征分析," *智能计算机与应用*, vol. 13, no. 1, pp. 153–157, 2023.
- [9] 成路平, 吴思扬, and 路波, "基于机器学习的 2 型糖尿病发病因素分析与预测," *医学信息学杂志*, vol. 46, no. 9, pp. 17–24, 2025.