

基于多种机器学习模型的糖尿病风险预测研究

柯文丽，王佳妮，秦琪，何晨东

华东师范大学

计算机科学与技术学院

《机器学习》课程项目

摘要—糖尿病风险预测是机器学习在健康管理场景中的典型二分类任务。本文基于 Pima Indians Diabetes Database 构建糖尿病风险预测系统，首先对不合理 0 值、隐式缺失、异常值和特征尺度进行统一处理，并采用分层抽样划分训练集、验证集和测试集。在模型实验阶段，本文以 Logistic Regression 作为基准模型，进一步比较 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM 等多种候选模型。在最终优化阶段，本文基于前序模型比较结果选择候选模型，采用 GridSearchCV 和 5 折 StratifiedKFold 进行超参数调优，并结合验证集 F1、Recall 和 ROC AUC 进行分类阈值选择。最终模型为阈值优化后的 SVM，测试集 Accuracy、Precision、Recall、F1-score 和 ROC AUC 分别为 0.7403、0.5972、0.7963、0.6825 和 0.8215。与 Logistic Regression 基准模型相比，最终模型在 Recall 和 F1-score 上取得提升，更符合问诊筛查场景中减少高风险漏判的目标。本文还基于 Gradio 构建了交互式问诊 Demo，实现单样本风险概率输出、风险等级展示、输入异常校验和简要建议。

Index Terms—糖尿病预测，Pima Indians Diabetes，机器学习，模型比较，超参数调优，ROC AUC，Gradio Demo

I. 引言

糖尿病是一类以慢性高血糖为主要表现的代谢性疾病。长期血糖控制不佳会增加心血管、肾脏、神经和视网膜等并发症风险。世界卫生组织和 Reza 等均指出，糖尿病仍是重要公共卫生问题，早期诊断和管理有助于预防或延缓并发症发生 [1], [2]。在常规筛查场景中，结构化体检指标比复杂医学检查更容易获取，因此利用机器学习模型进行糖尿病风险预测具有实际意义。

本文使用 Pima Indians Diabetes Database 开展二分类实验。该数据集包含 768 名样本、8 个数值型输入特征和 1 个二分类标签，样本均为至少 21 岁的 Pima Indian 女性 [3]。该数据集规模较小但变量清晰，适合

在统一预处理流程下比较不同分类算法的性能和误判特征。

本文目标是构建一个糖尿病风险预测项目：首先完成缺失值、异常值、标准化和分层划分等数据处理；其次以 Logistic Regression 作为可解释基准，并在统一实验协议下比较 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM 等多种模型；最后通过分类指标、ROC AUC、混淆矩阵和特征解释分析模型表现，并将最终模型接入交互式 Demo。

II. 相关工作

Smith 等较早使用 ADAP 学习算法研究 Pima 数据集上的糖尿病发病预测，并采用敏感性、特异性和 ROC 曲线等临床测试指标进行分析 [4]。Sisodia 等比较了 Decision Tree、SVM 和 Naive Bayes，Zou 等则结合特征降维比较了 Decision Tree、Random Forest 和神经网络；这些工作说明 Pima 数据集常被用于传统分类器和树模型比较 [5], [6]。

Khanam 和 Foo 系统比较了多种机器学习和神经网络模型，并强调缺失值填补、异常值处理、特征选择和归一化会影响最终结果 [7]。Reza 等进一步使用 stacking 方法融合传统机器学习模型和神经网络模型，并比较训练/测试划分与交叉验证协议 [2]。这些研究为本文选择多模型比较、统一预处理和多指标评估提供了依据。

在可解释性方面，Lundberg 和 Lee 提出的 SHAP 方法可通过特征边际贡献解释模型输出 [8]。李佳思和成路平等的研究均指出 Glucose、BMI 和 Age 等变量在糖尿病预测中较为重要 [9], [10]。

表 I
Pima 数据集输入特征说明

特征	含义	单位/说明	0 值处理
Pregnancies	怀孕次数	次	保留
Glucose	口服葡萄糖耐量测试 2 小时血糖浓度	-	缺失
BloodPressure	舒张压	mmHg	缺失
SkinThickness	三头肌皮褶厚度	mm	缺失
Insulin	2 小时血清胰岛素	$\mu\text{U/ml}$	缺失
BMI	身体质量指数	kg/m^2	缺失
DPF	糖尿病家族遗传指数	指数	保留
Age	年龄	岁	保留

III. 数据集与预处理

A. 数据集来源与变量定义

本文使用 Pima Indians Diabetes Database 进行实验。该数据集包含 768 条样本、8 个输入特征和 1 个二分类标签，所有输入特征均为数值型 [3]。标签 Outcome 中，0 表示未检测为糖尿病阳性，1 表示检测为糖尿病阳性。原始数据包含 500 个阴性样本和 268 个阳性样本，阳性样本占比约为 34.9%。图 1 展示了该类别分布。




图 1. 原始数据集中 Outcome 的类别分布

8 个输入变量的含义见表 I。Pregnancies 的 0 值表示没有怀孕经历，属于合理取值。Glucose、BloodPressure、SkinThickness、Insulin 和 BMI 的 0 值缺乏合理医学含义，因此本文将这些 0 值视作缺失或未测量记录 [2], [7]。

B. 缺失值与异常值处理

原始数据没有显式空值，但存在由不合理 0 值体现的隐式缺失。其中，Glucose 有 5 个 0，BloodPressure 有 35 个 0，SkinThickness 有 227 个 0，Insulin 有

表 II
训练集拟合得到的 IQR 裁剪边界

特征	下界	上界
Pregnancies	0.00	13.50
Glucose	38.75	200.75
BloodPressure	40.00	104.00
SkinThickness	1.00	57.00
Insulin	0.00	355.50
BMI	13.80	50.60
Diabetes Pedigree	0.00	1.2325
Age	0.00	65.25

表 III
分层划分后的样本量与类别分布

数据集	总样本数	0 类	1 类
训练集	491	320	171
验证集	123	80	43
测试集	154	100	54

374 个 0，BMI 有 11 个 0，若直接删除这些样本，会显著减少可用数据。由于中位数比均值更不易受偏态分布和极端值影响，因此，本文先将上述 5 个变量中的不合理 0 值标记为缺失，再使用训练集拟合得到的中位数填充。训练集填充值为 Glucose 117.0、BloodPressure 72.0、SkinThickness 29.0、Insulin 125.0 和 BMI 32.4。

在完成中位数填充后，本文采用 IQR 规则处理异常值。IQR 方法对特征分布形状没有正态性假设，适合 Pima 数据集中偏态较明显的生理指标。对每个特征，仅使用训练集计算第一四分位数 Q_1 、第三四分位数 Q_3 和四分位距

$$IQR = Q_3 - Q_1.$$

下界定义为 $\max(Q_1 - 1.5IQR, 0)$ ，上界定义为 $Q_3 + 1.5IQR$ 。随后使用训练集得到的边界对训练集、验证集和测试集进行一致裁剪，以避免验证集和测试集信息参与参数估计。表 II 给出了最终使用的裁剪边界。

C. 数据划分与标准化

数据划分采用分层抽样，随机种子为 42。首先划分 20% 样本作为测试集，再从剩余样本中划分 20% 作为验证集。最终训练集、验证集和测试集比例约为 64%、16% 和 20%，样本量和类别分布如表 III 所示。由于阳性样本约占 35%，分层抽样可以保持各子集的阳性/阴性比例接近原始数据。验证集用于模型选择和调参，测试集保留作最终评估，以减少调参过程对测试集的过拟合。

这样的划分比例兼顾了训练样本数量和评估结果的独立性。训练集占比最高，用于估计缺失填补、异常值裁剪和标准化参数，并承担所有模型的拟合过程；验证集用于比较候选模型、选择超参数和调整分类阈值；测试集则在模型结构、参数和阈值全部确定后才用于最终报告。固定随机种子使后续实验能够在相同数据划分上复现，也便于比较不同模型或不同阈值设置带来的性能变化。

标准化使用训练集拟合的均值和标准差完成。Logistic Regression、SVM、KNN 和神经网络等模型对特征尺度敏感，因此统一尺度有助于减少量纲差异对训练的影响。验证集、测试集和待预测样本只使用训练集拟合得到的参数进行变换，从而避免数据泄漏。

D. 探索性分析

图 2 展示了各特征在不同标签下的分布，并在存在不合理 0 值的变量上标注 0 值数量。从图中可以看到，阳性样本在 Glucose 和 BMI 上整体更偏向较高取值，Age 和 Pregnancies 也呈现一定右移趋势；同时，SkinThickness 和 Insulin 的 0 值数量明显较多，这与前文将其作为隐式缺失处理的决定一致。




图 2. 原始特征分布及不同类别对比

图 3 由原始数据中的全部数值列计算 Pearson 相关系数得到，并用热力图展示特征之间以及特征与标签之间的线性相关程度。从标签 Outcome 对应的相关系数看，Glucose 与标签的相关性最高，约为 0.47；BMI、Age、Pregnancies 和 DiabetesPedigreeFunction 也与标签呈正相关，但强度弱于 Glucose。特征之间的相关性总体不算很高，其中 Pregnancies 与 Age、SkinThickness 与 Insulin、SkinThickness 与 BMI 的相关性相对更明显。这些结果说明血糖、体重相关指标和年龄信息可能对模型




图 3. 原始特征与标签的相关性热力图

预测较有帮助，但相关性只反映线性统计关联，不能直接解释为医学因果关系。

IV. 方法与实验设置

A. 整体流程

为保证模型比较的公平性和结果评估的独立性，本文将数据划分、预处理参数估计、模型训练与最终评估明确分离。首先在原始数据上标记缺乏合理医学含义的 0 值，随后采用分层抽样得到训练集、验证集和测试集。中位数填充器、IQR 裁剪边界和标准化器均仅在训练集上拟合，再以相同参数作用于验证集、测试集和系统端待预测样本。验证集用于模型筛选、超参数调优和分类阈值选择，测试集只用于最终性能报告。图 4 展示了离线实验流程与在线问诊系统推理流程之间的关系。

整体流程可概括为数据清洗、分层划分、训练集拟合预处理、模型训练/调参与独立测试评估。不合理 0 值、IQR 裁剪和标准化均只在训练集上估计参数，再复用于验证集、测试集和系统端单样本输入。系统展示阶段将最终模型与预处理对象共同封装，保证交互界面中的风险预测与离线实验使用相同的特征顺序和数据变换规则。

B. 模型选择

本文首先使用 Logistic Regression 作为可解释基准模型：设置 `class_weight="balanced"`、最大迭代次数 1000、随机种子 42，并将其作为后续模型比较的参照。在此基础上，多模型比较阶段使用同一组训练集、




图 4. 糖尿病风险预测系统总体技术路线

验证集和测试集，并复用由训练集拟合得到的预处理参数，不再重复清洗或重新划分数据。所有候选模型均只在训练集上拟合，并分别在验证集和测试集上使用相同指标进行评估，从而保证不同模型之间以及与 Logistic Regression 基准模型之间的公平可比性。

除 Logistic Regression 基准模型外，实验纳入 KNN、Decision Tree、Random Forest、SVM、Gradient Boosting、XGBoost 和 LightGBM。这些模型覆盖距离方法、线性模型、最大间隔分类器、单树模型和集成学习，便于在统一预处理协议下比较不同建模假设。

本文采用统一协议计算 Accuracy、Precision、Recall、F1-score 和 ROC AUC。由于糖尿病风险预测属于筛查任务，漏判高风险样本可能使潜在阳性个体错过进一步检查，因此模型比较不能只关注 Accuracy，还应重点观察 Recall 和 F1-score，并结合 ROC AUC 衡量模型对正负样本的整体排序能力。

C. 超参数调优协议

多模型比较完成后，本文仅依据验证集结果确定调参对象，避免测试集信息参与模型选择。SVM 在验证集 Recall 和 F1-score 上表现最好，Logistic Regression 作为可解释线性基准保留作对照，因此最终调参阶段聚焦于这两个模型。

调参采用 GridSearchCV，交叉验证方式为 5 折 StratifiedKfold，划分时设置 shuffle=True 和随机种子 42，搜索评分指标为 ROC AUC。Logistic Regression 的搜索空间包括 $C \in \{0.01, 0.1, 1, 10, 100\}$ 、solver $\in \{\text{liblinear}, \text{lbfgs}\}$ 、penalty=l2 以及 class_weight $\in \{\text{None}, \text{balanced}\}$ 。SVM 采用 RBF 核，搜索空间包括 $C \in \{0.1, 1, 10, 100\}$ 、gamma $\in \{\text{scale}, 0.01, 0.1, 1\}$ 以及 class_weight $\in \{\text{None}, \text{balanced}\}$ 。

得到最优超参数后，本文在验证集上以 0.01 为步长搜索 0.25–0.75 范围内的分类阈值，并以 F1-score、

Recall 和 ROC AUC 综合排序。由于筛查场景更关注减少假阴性，最终阈值选择优先保证较高 Recall。

最终选择的模型为 SVM，最优参数为 $C = 10.0$ 、gamma=0.01、class_weight=None，验证集上选择的分类阈值为 0.30。调参结果保存为 tuning_results.csv，最优参数和模型选择依据保存为 best_params.json，最终模型保存为 models/best_model.pkl。

D. 评价指标

糖尿病预测是类别不平衡二分类问题，单一 Accuracy 可能掩盖阳性样本漏判。因此本文纳入 Accuracy、Precision、Recall、F1-score 和 ROC AUC 作为评价指标。其中 Recall 衡量真实阳性样本被正确识别的比例；在筛查场景中，假阴性意味着潜在高风险个体被漏掉，因此 Recall 和 F1-score 比单纯 Accuracy 更需要关注。ROC AUC 不依赖单一分类阈值，用于衡量模型对阳性样本的概率排序能力。

V. 结果与分析

A. 模型性能比较

表 IV 汇总了 Logistic Regression 基准模型以及 7 个候选模型在验证集和测试集上的性能。所有模型使用相同的预处理结果和固定数据划分，并仅使用训练集进行拟合，表中结果可用于比较不同模型在基础参数设置下的表现。

图 5 进一步展示了各模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC。由于糖尿病风险预测不能只关注总体预测正确率，本文在比较候选模型时重点考察 Recall 和 F1-score，并使用 ROC AUC 衡量模型对正负样本的整体排序能力。

在基础参数设置下，SVM 与 XGBoost 的测试集 Accuracy 均为 0.7468，并列所有模型中的最高值。其中 SVM 的 Recall 和 F1-score 分别为 0.7778 和 0.6829，




图 5. 不同模型在测试集上的 Accuracy、Recall、F1-score 和 ROC AUC 对比

均为候选模型最高，较 Logistic Regression 基准有明显提升。Random Forest 的 ROC AUC 最高，为 0.8275，但 Recall 仅为 0.5370，说明其排序能力较好而默认阈值下漏判较多。XGBoost 的 Precision 较高但 Recall 偏低，LightGBM 表现较均衡，Decision Tree 和 Gradient Boosting 相对较弱。综合验证集与测试集结果，本文选择阳性召回和 F1-score 更稳定的 SVM 作为主要调参对象，并保留 Logistic Regression 作为线性基准。

从验证集与测试集的差异还可以看出，小样本条件下单次划分会带来一定波动。例如，SVM 的验证集 Recall 为 0.8372，测试集 Recall 为 0.7778；Random Forest 则在测试集上取得较高 AUC，但默认阈值下的 Recall 较低。因此，模型选择不能仅依据某一个指标或某一次测试结果，而应同时考察跨数据子集的稳定性和筛查任务的漏判代价以及后续阈值调整空间。ROC AUC 描述模型在全部可能阈值下区分正负样本的总体能力，但不直接代表某个部署阈值下的分类效果 [11]；这也是本文同时报告 AUC、Recall、Precision 和 F1-score 的原因。

不同模型之间的性能差异也反映了数据规模与模型复杂度之间的关系。Pima 数据集仅包含 768 条记录和 8 个结构化特征，复杂集成模型虽然能够刻画更高阶的非线性关系，但在样本有限、部分变量缺失比例较高的条件下，其优势可能被估计方差和过拟合风险抵消。例如，XGBoost 与 SVM 的测试集 Accuracy 相同，但前者 Recall 明显较低；Decision Tree 的验证集与测试集 AUC 均低于多数候选模型，也说明单棵树对当前数据划分较为敏感。相较之下，Logistic Regression 和 SVM

的决策边界受到更强约束，在本实验中表现出较好的泛化稳定性。

这一结果与既有糖尿病预测研究中“不同算法不存在始终占优者”的现象一致：模型表现会受到数据来源、预处理方式、评价指标及划分策略共同影响 [5]–[7]。因此，本文不以单一 Accuracy 排名直接确定最终模型，而是将多模型比较作为候选筛选阶段，再围绕风险筛查所关注的阳性召回能力进行调参与阈值优化。这种选择逻辑既保留了不同模型的实验对照价值，也使最终决策标准与系统的实际使用目标保持一致。

B. 最终调优结果

在最终调参阶段，本文没有直接依据测试集结果选择模型，而是基于验证集表现筛选候选模型并进行 GridSearchCV 调参。本次进入调参的模型为 SVM 和 Logistic Regression。两者交叉验证 ROC AUC 接近，但阈值调整后 SVM 在 Recall 和 F1-score 上更优，更符合筛查任务中优先降低漏判风险的目标。

表 V
调参候选模型在验证集上的表现

模型	CV AUC	阈值	Recall	F1	AUC
Logistic Regression	0.8421	0.43	0.7209	0.7126	0.8689
SVM	0.8425	0.30	0.8372	0.7347	0.8762

表 V 显示，SVM 在阈值 0.30 下取得 0.8372 的验证集 Recall 和 0.7347 的 F1-score。该阈值体现了风险筛查任务中宁可增加少量提示、也要尽量减少高风险漏判的偏好。

表 IV
模型性能比较表

模型	Val Acc.	Val Prec.	Val Recall	Val F1	Val AUC	Test Acc.	Test Prec.	Test Recall	Test F1	Test AUC
Logistic Regression	0.7642	0.6346	0.7674	0.6947	0.8709	0.7273	0.5938	0.7037	0.6441	0.8154
KNN	0.7805	0.7105	0.6279	0.6667	0.8581	0.7273	0.6154	0.5926	0.6038	0.7675
Decision Tree	0.7886	0.7429	0.6047	0.6667	0.7461	0.6948	0.5714	0.5185	0.5437	0.6543
Random Forest	0.7967	0.7368	0.6512	0.6914	0.8365	0.7338	0.6444	0.5370	0.5859	0.8275
SVM	0.7967	0.6667	0.8372	0.7423	0.8759	0.7468	0.6087	0.7778	0.6829	0.8157
Gradient Boosting	0.7236	0.6098	0.5814	0.5952	0.8311	0.7013	0.5952	0.4630	0.5208	0.7959
XGBoost	0.7561	0.6857	0.5581	0.6154	0.7985	0.7468	0.6596	0.5741	0.6139	0.7967
LightGBM	0.7724	0.6923	0.6279	0.6585	0.8308	0.7273	0.6304	0.5370	0.5800	0.8002

阈值选择严格在验证集上完成，测试集仅用于最终一次性能评估，以避免根据测试结果反复修改模型而产生信息泄露。从应用角度看，阈值不是固定不变的模型参数，而是与筛查资源和错误代价相关的决策参数：阈值降低通常能够发现更多潜在阳性样本，但也会增加后续复查数量。此外，SVM 输出分数适合用于排序和阈值决策，却不一定等同于经过校准的真实患病概率；已有研究表明，不同分类器的概率估计质量存在明显差异，实际部署前还应使用独立数据评估可靠性并进行概率校准 [12]。

最终选定的 SVM 最佳参数为 $C = 10.0$ 、 $\text{gamma}=0.01$ 、 $\text{class_weight}=\text{None}$ ，验证集分类阈值为 0.30。阈值调整后的最终模型在测试集上的 Accuracy、Precision、Recall、F1-score 和 ROC AUC 分别为 0.7403、0.5972、0.7963、0.6825 和 0.8215。

表 VI
最终模型与基准模型测试集结果对比

指标	基准模型	最终模型	变化
Accuracy	0.7273	0.7403	+0.0130
Precision	0.5938	0.5972	+0.0034
Recall	0.7037	0.7963	+0.0926
F1-score	0.6441	0.6825	+0.0384
ROC AUC	0.8154	0.8215	+0.0061

表 VI 显示，最终模型相较基准模型 Recall 提升 0.0926，F1-score 提升 0.0384，符合减少高风险漏判的筛查目标。

C. 误判与 ROC 分析

当前基准模型在验证集上的混淆矩阵为：TN=61、FP=19、FN=10、TP=33；在测试集上为：TN=74、FP=26、FN=16、TP=38。最终模型在测试集上的混淆矩阵为：TN=71、FP=29、FN=11、TP=43。与基准模型相比，最终模型将测试集假阴性数量由 16 降低到 11，说明阈值

优化后的 SVM 能识别更多真实阳性样本；FP 增加则体现了提升 Recall 所付出的 Precision 代价。

进一步换算可得，基准模型的假阴性率为 $16/54 = 0.2963$ ，最终模型降至 $11/54 = 0.2037$ ；与此同时，特异度由 $74/100 = 0.7400$ 降至 $71/100 = 0.7100$ 。也就是说，模型以增加 3 个假阳性为代价，减少了 5 个假阴性。对于强调尽早识别高风险个体的初筛场景，这一交换具有实际意义，但若复查成本较高，则仍需结合具体资源重新设定阈值。




图 6. 最终模型在测试集上的混淆矩阵

图 7 展示了最终模型在测试集上的 ROC 曲线。最终模型测试集 ROC AUC 为 0.8215，说明其对阳性样本和阴性样本仍具有较好的概率排序能力。由于 ROC AUC 不依赖单一分类阈值，该指标可以从整体上反映模型区分能力；而 Recall、Precision 和 F1-score 则反映了阈值确定后的实际分类效果。本文在最终系统中采用 0.30 作为分类阈值，主要是为了在保持可接受总体性能

的同时提高高风险样本召回率。

值得注意的是，最终模型相较基准模型的 AUC 仅提高 0.0061，而 Recall 提高 0.0926，说明召回改善主要来自模型分数与决策阈值的共同调整，并非排序能力发生同等幅度的提升。因此，ROC 曲线适合评价模型的整体区分能力，混淆矩阵和阈值相关指标则用于判断具体决策规则是否符合筛查目标；两类结果应结合解读 [11]。




图 7. 最终模型在测试集上的 ROC 曲线

D. 特征解释

当前可用的解释结果来自 Logistic Regression 基准模型。基准模型系数和最终模型 permutation importance 均表明，Glucose、BMI、Pregnancies、Age 和 DiabetesPedigreeFunction 是较重要的预测变量，其中 Glucose、BMI 和 Age 与相关研究结论基本一致 [9], [10]。

在最终模型解释阶段，本文进一步使用 permutation importance 对阈值优化后的 SVM 进行特征重要性分析，结果如图 8 所示。Permutation importance 衡量打乱某一特征后模型 ROC AUC 的平均下降幅度，因此更适合用于解释非线性模型对不同输入变量的依赖程度。这种基于随机置换评估变量贡献的思想也常用于树模型的模型无关解释 [13]。




图 8. 最终模型特征重要性 (Permutation Importance)

最终模型中，Glucose 的重要性均值为 0.155259，明显高于其他特征，说明血糖值是模型进行糖尿病风险判断时最关键的输入因素。BMI、Pregnancies、Age 和 DiabetesPedigreeFunction 也具有较高重要性，这与前文探索性分析和基准模型系数排序基本一致。Insulin、BloodPressure 和 SkinThickness 的重要性相对较低，其中 SkinThickness 的置换重要性均值略为负值，可能与该变量缺失比例较高、填充后信息量有限以及测试集样本量较小有关。负重要性并不表示该特征对糖尿病具有“保护作用”，而表示在当前有限测试样本上，打乱该变量没有稳定降低模型性能。同时，当多个特征相关时，一个特征被置换后，其他相关特征仍可能提供替代信息，从而使重要性被分散或低估；条件置换重要性研究也指出，解释相关变量时需要显式考虑特征间依赖关系 [14]。因此，本节将重要性结果用于识别模型依赖和生成解释线索，而不将其作为变量因果效应或临床诊断依据。需要强调的是，特征重要性反映模型在当前数据集上的预测依赖，不能直接解释为医学因果关系。

E. 系统演示

本文基于 Gradio 构建了单样本糖尿病风险预测 Demo。系统输入与 Pima 数据集 8 个特征保持一致，并严格复用训练阶段保存的中位数填充器、IQR 裁剪边界、标准化器和最终 SVM 模型。对于 0 值或明显越界的医学指标，系统先返回“输入异常 / 无法评估”提示；通过校验后再输出阳性概率、低/中/高风险等级以及简要因素说明。该系统仅用于课程展示和风险提示，不能替代医学诊断。

表 VII
团队成员分工

成员	主要负责内容
柯文丽	数据理解、数据预处理、数据划分与基准模型
王佳妮	交互式问诊系统设计、模型推理流程封装、系统集成
秦琪	多模型训练、模型性能对比与结果整理
何晨东	参数调优、最终模型评估与结果可视化分析

VI. 结论、局限性与分工

A. 结论与局限性

在统一预处理和固定数据划分下，SVM 在基础比较中取得最高的 Recall 和 F1-score；进一步调参后，阈值为 0.30 的 SVM 在测试集上达到 0.7403 Accuracy、0.7963 Recall、0.6825 F1-score 和 0.8215 ROC AUC。相较 Logistic Regression 基准模型，最终模型将 Recall 从 0.7037 提升到 0.7963，并将假阴性数量由 16 降至 11，说明其更适合课程项目中的风险筛查目标。

本文还基于 Gradio 构建了问诊 Demo，复用训练阶段保存的预处理对象和最终模型，输出风险概率、风险等级和简要因素说明，并对明显不合理输入进行拦截。局限性在于 Pima 数据集样本量较小、人群范围有限，且只包含 8 个结构化指标。后续可扩大数据来源，引入更多临床变量，并尝试概率校准、代价敏感学习和 SHAP 等个体级解释方法。

B. 团队分工

本项目采用模块化分工方式完成，各成员同时参与对应模块的报告与展示内容整理。

参考文献

[1] World Health Organization, “Diabetes,” Fact sheet, 2024, updated November 2024; available at <https://www.who.int/news-room/fact-sheets/detail/diabetes>.

[2] M. S. Reza, R. Amin, R. Yasmin, W. Kulsum, and S. Ruhi, “Improving diabetes disease patients classification using stacking ensemble method with PIMA and local healthcare data,” *Heliyon*, vol. 10, no. 2, p. e24536, Jan. 2024.

[3] National Institute of Diabetes and Digestive and Kidney Diseases, “Pima Indians Diabetes Database,” UCI Machine Learning Repository, 1990, dataset description; 768 instances, 8 attributes plus class.

[4] J. W. Smith, J. Everhart, W. Dickson, W. Knowler, and R. Johannes, “Using the ADAP Learning Algorithm to Forecast the Onset of Diabetes Mellitus,” *Proceedings of the Annual Symposium on Computer Application in Medical Care*, pp. 261–265, Nov. 1988.

[5] D. Sisodia and D. S. Sisodia, “Prediction of Diabetes using Classification Algorithms,” *Procedia Computer Science*, vol. 132, pp. 1578–1585, Jan. 2018.

[6] Q. Zou, K. Qu, Y. Luo, D. Yin, Y. Ju, and H. Tang, “Predicting Diabetes Mellitus With Machine Learning Techniques,” *Frontiers in Genetics*, vol. 9, Nov. 2018.

[7] J. J. Khanam and S. Y. Foo, “A comparison of machine learning algorithms for diabetes prediction,” *ICT Express*, vol. 7, no. 4, pp. 432–439, Dec. 2021.

[8] S. M. Lundberg and S.-I. Lee, “A Unified Approach to Interpreting Model Predictions,” in *Advances in Neural Information Processing Systems*, vol. 30. Curran Associates, Inc., 2017.

[9] 李佳思, “基于机器学习的糖尿病预测及 SHAP 特征分析,” *智能计算机与应用*, vol. 13, no. 1, pp. 153–157, 2023.

[10] 成路平, 吴思扬, and 路波, “基于机器学习的 2 型糖尿病发病因素分析与预测,” *医学信息学杂志*, vol. 46, no. 9, pp. 17–24, 2025.

[11] T. Fawcett, “An introduction to ROC analysis,” *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006.

[12] A. Niculescu-Mizil and R. Caruana, “Predicting good probabilities with supervised learning,” in *Proceedings of the 22nd International Conference on Machine Learning*, 2005, pp. 625–632.

[13] L. Breiman, “Random forests,” *Machine Learning*, vol. 45, no. 1, pp. 5–32, 2001.

[14] D. Debeer and C. Strobl, “Conditional permutation importance revisited,” *BMC Bioinformatics*, vol. 21, p. 307, 2020.